

Numpy, la brique de base de la data science

Lino Galiana

Version du 29 septembre 2026

`Numpy` constitue la brique de base de l'écosystème de la *data science* en `Python`. Toutes les bibliothèques de manipulation de données, de modélisation et de visualisation reposent, de manière plus ou moins directe, sur `Numpy`. Il est donc indispensable de revoir quelques notions sur ce package avant d'aller plus loin.

 **PDF généré automatiquement.** Ce document est produit à partir du site du cours et peut présenter des problèmes de mise en forme. Pour une version à jour et adaptée à la lecture, consultez la page du cours : pythonands.linogaliana.fr.

Table des matières

1 Introduction	1
2 Le concept d'<i>array</i>	2
2.1 Créer un <i>array</i>	2
3 Indexation et <i>slicing</i>	4
3.1 Logique dans le cas d'un <i>array</i> unidimensionnel	4
3.2 Sur la performance	6
3.3 Filtres logiques	6
4 Manipuler un <i>array</i>	7
4.1 Fonctions de manipulation	7
4.2 Statistiques sur un <i>array</i>	8
5 Simulations numériques	8
5.1 Loi des grands nombres	9
5.2 Distribution de résultats de lancer de pièces	12
6 <i>Broadcasting</i>	13
6.1 Une application: programmer ses propres k-nearest neighbors	14
7 Exercices supplémentaires	16
Informations additionnelles	17

1 Introduction

Ce chapitre constitue une introduction à `Numpy` pour s'assurer que les bases du calcul vectoriel avec `Python` soient maîtrisées. La première partie du chapitre présente des petits exercices pour pratiquer quelques fonctions basiques de `Numpy`. La fin du chapitre présente des exercices pratiques d'utilisation de `Numpy` plus approfondis.

Il est recommandé de régulièrement se référer à la [cheatsheet numpy](#) et à la [doc officielle](#) en cas de doute sur une fonction.

Dans ce chapitre, on ne dérogera pas à la convention qui s'est imposée d'importer `Numpy` de la manière suivante :

```
import numpy as np
```

Nous allons également fixer la racine du générateur aléatoire de nombres afin d'avoir des résultats reproductibles :

```
import numpy as np
rng = np.random.default_rng(seed=12345)
```

Caution

Historiquement, la génération de nombres aléatoires se faisait pas le biais du package `numpy.random`. Néanmoins, les auteurs de `Numpy` recommandent maintenant d'utiliser plutôt des générateurs pour cela. Les exemples de ce tutoriel adoptent donc cette pratique.

2 Le concept d'*array*

Dans le monde de la science des données, comme cela sera évoqué plus en profondeur dans les prochains chapitres, l'objet central est le tableau à deux dimensions de données. La première correspond aux lignes et la seconde aux colonnes. Si on ne se préoccupe que d'une dimension, on se rapporte à une variable (une colonne) de notre tableau de données. Il est donc naturel de faire le lien entre les tableaux de données et l'objet mathématique que sont les matrices et les vecteurs.

`NumPy` (`Numerical Python`) est la brique de base pour traiter des listes numériques ou des chaînes de textes comme des matrices. `NumPy` intervient pour proposer ce type d'objets, et les opérations standardisées associées qui n'existent pas dans le langage `Python` de base.

L'objet central de `NumPy` est l'`array` qui est un tableau de données multidimensionnel. L'`array` `NumPy` peut être unidimensionnel et s'apparenter à un vecteur (`1d-array`), bidimensionnel et ainsi s'apparenter à une matrice (`2d-array`) ou, de manière plus générale, prendre la forme d'un objet multidimensionnel (`Nd-array`), sorte de tableau emboîté.

Les tableaux simples (uni ou bi-dimensionnels) sont faciles à se représenter et représentent la majorité des besoins liés à `NumPy`. Nous découvrirons lors du chapitre suivant, sur `Pandas`, qu'en pratique on manipule rarement directement `NumPy` qui est une librairie bas niveau. Un `DataFrame` `Pandas` sera construit à partir d'une collection d'`array` uni-dimensionnels (les variables de la table), ce qui permettra d'effectuer des opérations cohérentes (et optimisées) avec le type de la variable. Avoir quelques notions `NumPy` est utile pour comprendre la logique de manipulation vectorielle rendant les traitements sur des données plus lisibles, plus efficaces et plus fiables.

Par rapport à une liste,

- un `array` ne peut contenir qu'un type de données (`integer`, `string`, etc.), contrairement à une liste.
- les opérations implémentées par `NumPy` seront plus efficaces et demanderont moins de mémoire

Les données géographiques constitueront une construction un peu plus complexe qu'un `DataFrame` traditionnel. La dimension géographique prend la forme d'un tableau plus profond, au moins bidimensionnel (coordonnées d'un point). Néanmoins, les librairies de manipulation de données géographiques permettront de ne pas se préoccuper de cette complexité accrue.

2.1 Créer un `array`

On peut créer un `array` de plusieurs manières. Pour créer un `array` à partir d'une liste, il suffit d'utiliser la méthode `array`:

```
np.array([1,2,5])
```

```
array([1, 2, 5])
```

Il est possible d'ajouter un argument `dtype` pour contraindre le type du `array` :

```
np.array(["a", "z", "e"], ["r", "t"], ["y"], dtype="object")
```

```
array([list(['a', 'z', 'e']), list(['r', 't']), list(['y'])], dtype=object)
```

Il existe aussi des méthodes pratiques pour créer des `array` :

- séquences logiques : `np.arange` (suite) ou `np.linspace` (interpolation linéaire entre deux bornes) ;
- séquences ordonnées : `array` rempli de zéros, de 1 ou d'un nombre désiré : `np.zeros`, `np.ones` ou `np.full` ;
- séquences aléatoires : fonctions de génération de nombres aléatoires : `rng.uniform`, `rng.normal`, etc. où `rng` est un générateur de nombre aléatoires ;
- tableau sous forme de matrice identité : `np.eye`.

Ceci donne ainsi, pour les séquences logiques:

```
np.arange(0,10)
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

```
np.arange(0,10,3)
```

```
array([0, 3, 6, 9])
```

```
np.linspace(0, 1, 5)
```

```
array([0. , 0.25, 0.5 , 0.75, 1.  ])
```

Pour un `array` initialisé à 0:

```
np.zeros(10, dtype=int)
```

```
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0])
```

ou initialisé à 1:

```
np.ones((3, 5), dtype=float)
```

```
array([[1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.]])
```

ou encore initialisé à 3.14:

```
np.full((3, 5), 3.14)
```

```
array([[3.14, 3.14, 3.14, 3.14, 3.14],
       [3.14, 3.14, 3.14, 3.14, 3.14],
       [3.14, 3.14, 3.14, 3.14, 3.14]])
```

Enfin, pour créer la matrice I_3 :

```
np.eye(3)
```

```
array([[1., 0., 0.],
       [0., 1., 0.],
       [0., 0., 1.]])
```

💡 Exercice 1

Générer:

- X une variable aléatoire, 1000 répétitions d'une loi $U(0, 1)$
- Y une variable aléatoire, 1000 répétitions d'une loi normale de moyenne nulle et de variance égale à 2
- Vérifier la variance de Y avec `np.var`

3 Indexation et *slicing*

3.1 Logique dans le cas d'un array unidimensionnel

La structure la plus simple est l'*array* unidimensionnel:

```
x = np.arange(10)
print(x)
```

```
[0 1 2 3 4 5 6 7 8 9]
```

L'indexation est dans ce cas similaire à celle d'une liste:

- le premier élément est 0
- le n ème élément est accessible à la position $n - 1$

La logique d'accès aux éléments est ainsi la suivante :

```
x[start:stop:step]
```

Avec un *array* unidimensionnel, l'opération de *slicing* (garder une coupe du *array*) est très simple. Par exemple, pour garder les K premiers éléments d'un *array*, on fera:

```
x[:K]
```

En l'occurrence, on sélectionne le K^{eme} élément en utilisant

```
x[K-1]
```

Pour sélectionner uniquement un élément, on fera ainsi:

```
x = np.arange(10)
x[2]
```

```
np.int64(2)
```

Les syntaxes qui permettent de sélectionner des indices particuliers d'une liste fonctionnent également avec les *arrays*.

💡 Exercice 2

Prenez `x = np.arange(10)` et...

- Sélectionner les éléments 0, 3, 5 de `x`
- Sélectionner les éléments pairs
- Sélectionner tous les éléments sauf le premier
- Sélectionner les 5 premiers éléments

```
np.arange(10)
```

```
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
```

La logique se généralise pour les *array* multidimensionnels. L'indexation se fait alors à plusieurs niveaux. Prenons par exemple un *array* à 2 dimensions (une matrice en quelques sortes):

```
x = np.array([[1, 2, 3], [4, 5, 6]], np.int32)
```

Si on veut sélectionner la 2e ligne, 3e colonne (l'élément de valeur 6), on fait

```
x[1, 2]
```

```
np.int32(6)
```

Maintenant, pour sélectionner une colonne complète (par exemple la 2e), on peut utiliser le 2e index pour spécifier celle-ci (index 1 en Python puisque l'indexation part de 0) puis `:` sur la première dimension (version raccourcie de `0:N`) pour ne pas discriminer selon cette dimension:

```
x[:, 1]
```

```
array([2, 5], dtype=int32)
```

Le principe se généralise, mais se complexifie, pour des *array* imbriqués. Heureusement, ce sont des objets qu'on manipule assez rarement directement, la plupart de nos données numériques étant des tableaux plats (une valeur - l'observation - est le croisement d'une ligne - l'individu - et d'une colonne - la variable).

3.2 Sur la performance

Un élément déterminant dans la performance de `Numpy` par rapport aux listes, lorsqu'il est question de *slicing* est qu'un array ne renvoie pas une copie de l'élément en question (copie qui coûte de la mémoire et du temps) mais simplement une vue de celui-ci.

Lorsqu'il est nécessaire d'effectuer une copie, par exemple pour ne pas altérer l'*array* sous-jacent, on peut utiliser la méthode `copy`:

```
x_sub_copy = x[:2, :2].copy()
```

3.3 Filtres logiques

Il est également possible, et plus pratique, de sélectionner des données à partir de conditions logiques (opération qu'on appelle un *boolean mask*). Cette fonctionnalité servira principalement à effectuer des opérations de filtre sur les données.

Pour des opérations de comparaison simples, les comparateurs logiques peuvent être suffisants. Ces comparaisons fonctionnent aussi sur les tableaux multidimensionnels grâce au *broadcasting* sur lequel nous reviendrons :

```
x = np.arange(10)
x2 = np.array([[ -1, 1, -2], [-3, 2, 0]])
print(x)
print(x2)
```

```
[0 1 2 3 4 5 6 7 8 9]
[[-1  1 -2]
 [-3  2  0]]
```

```
x==2
x2<0
```

```
array([[ True, False,  True],
       [ True, False, False]])
```

Pour sélectionner les observations relatives à la condition logique, il suffit d'utiliser la logique de *slicing* de `numpy` qui fonctionne avec les conditions logiques

💡 Exercice 3

Soit

```
x = np.random.normal(size=10000)
```

1. Ne conserver que les valeurs dont la valeur absolue est supérieure à 1.96
2. Compter le nombre de valeurs supérieures à 1.96 en valeur absolue et leur proportion dans l'ensemble
3. Sommer les valeurs absolues de toutes les observations supérieures (en valeur absolue) à 1.96 et rapportez les à la somme des valeurs de `x` (en valeur absolue)

Lorsque c'est possible, il est recommandé d'utiliser les fonctions logiques de `numpy` (optimisées et qui gèrent bien la dimension). Parmi elles, on peut retrouver:

- `count_nonzero` ;
- `isnan` ;
- `any` ou `all`, notamment avec l'argument `axis` ;
- `np.array_equal` pour vérifier, élément par élément, l'égalité.

Soient `x` un `array` multidimensionnel et `y` un `array` unidimensionnel présentant une valeur manquante.

```
# Assuming rng has been created beforehand
x = rng.normal(0, size=(3, 4))
y = np.array([np.nan, 0, 1])
```

💡 Exercice 4

1. Utiliser `count_nonzero` sur `y`
2. Utiliser `isnan` sur `y` et compter le nombre de valeurs non NaN
3. Vérifier que `x` comporte au moins une valeur positive dans son ensemble, en parcourant les lignes puis les colonnes.

Aide Jetez un oeil au paramètre `axis` en vous documentant sur internet. Par exemple [ici](#).

4 Manipuler un *array*

4.1 Fonctions de manipulation

`Numpy` propose des méthodes ou des fonctions standardisées pour modifier un `array`, voici un tableau en présentant quelques-unes:

Opération	Implémentation
Aplatir un <code>array</code>	<code>x.flatten()</code> (méthode)
Transposer un <code>array</code>	<code>x.T</code> (méthode) ou <code>np.transpose(x)</code> (fonction)
Ajouter des éléments à la fin	<code>np.append(x, [1,2])</code>
Ajouter des éléments à un endroit donné (aux positions 1 et 2)	<code>np.insert(x, [1,2], 3)</code>
Supprimer des éléments (aux positions 0 et 3)	<code>np.delete(x, [0,3])</code>

Pour combiner des `array`, on peut utiliser, selon les cas, les fonctions `np.concatenate`, `np.vstack` ou la méthode `.r_` (concaténation *rowwise*). `np.hstack` ou la méthode `.column_stack` ou `.c_` (concaténation *column-wise*)

```
x = rng.normal(size = 10)
```

Pour ordonner un `array`, on utilise `np.sort`

```
x = np.array([7, 2, 3, 1, 6, 5, 4])

np.sort(x)
```

```
array([1, 2, 3, 4, 5, 6, 7])
```

Si on désire faire un ré-ordonnement partiel pour trouver les k valeurs les plus petites d'un `array` sans les ordonner, on utilise `partition`:

```
np.partition(x, 3)
```

```
array([1, 2, 3, 4, 5, 6, 7])
```

4.2 Statistiques sur un `array`

Pour les statistiques descriptives classiques, `Numpy` propose un certain nombre de fonctions déjà implémentées, qui peuvent être combinées avec l'argument `axis`

```
x = rng.normal(0, size=(3, 4))
```

💡 Exercice 5

1. Faire la somme de tous les éléments d'un `array`, des éléments en ligne et des éléments en colonne. Vérifier la cohérence.
2. Ecrire une fonction `statdesc` pour renvoyer les valeurs suivantes : moyenne, médiane, écart-type, minimum et maximum. L'appliquer sur `x` en jouant avec l'argument `axis`

5 Simulations numériques

`Numpy` est incontournable dès lors qu'on effectue des simulations aléatoires, ce qui est très commun en statistiques computationnelles avec un ensemble de méthodes dites de Monte-Carlo. Le principe général est de remplacer un calcul théorique difficile (une intégrale, une probabilité, une espérance) par une approximation numérique obtenue en répétant un grand nombre de tirages aléatoires et en moyennant la quantité d'intérêt, en s'appuyant sur la loi des grands nombres et le théorème central limite pour quantifier la précision de l'estimation.

Illustrons empiriquement quelques théorèmes incontournables de la statistique par une série d'exercices. Cela permettra d'explorer :

- La loi des grands nombres (Tip 1);
- Le théorème central limite et sa version particulière dans le cas de lancer de pièce, le [théorème de Moivre-Laplace](#) ;
- Les intervalles de confiance théoriques et leur contrepartie empirique à travers le *bootstrap* ;
- Le principe des méthodes de Monte Carlo avec l'algorithme du rejet.

Nous allons avoir besoin des éléments suivants pour initialiser notre processus générateur de données.

```
import numpy as np

def generate_grid(size_max=1000):
    n_small = np.arange(3, 200, 2)
```

```

n_log = np.unique(np.round(np.logspace(np.log10(200), np.log10(size_max), 120)).astype(int))
return np.unique(np.concatenate([n_small, n_log]))

N_max = 100_000
rng = np.random.default_rng(seed=123)
grid = generate_grid(size_max=N_max)

```

Ces éléments nous permettent de générer une série aléatoire d'observations jusqu'à une taille `N_max`, puis d'observer l'évolution des estimateurs empiriques de moments (moyenne et variance) lorsque l'on ne conserve que les `n` premières observations, pour différents `n` donnés par `grid`. L'objectif est d'illustrer la convergence des estimateurs empiriques vers leurs valeurs théoriques lorsque `n` augmente.

5.1 Loi des grands nombres

Nous sommes accoutumés à faire le lien, assez intuitif, entre la théorie des probabilités et la statistique. C'est notamment possible grâce à des théorèmes comme le [théorème fondamental de la statistique](#) ([théorème de Glivenko-Cantelli](#)). Cette relation est le fondement de la science des données, et plus globalement de la statistique, dans sa dimension inférentielle comme descriptive, puisque sans des intuitions mathématiques formelles nous aurions du mal à généraliser les interprétations issues de données observées.

La [loi des grands nombres](#) peut être illustrée assez facilement par le biais de simulations numériques. Nous allons simuler une suite répétée de tirages aléatoires, ce sera l'équivalent pratique de la suite i.i.d. $(X)_i$ du théorème.

💡 Astuce 1: Exercice 6: la loi des grands nombres

On considère une suite i.i.d. $(X_i)_{i \geq 1}$ telle que $X_i \sim \mathcal{U}([0, 1])$.

1. Générer un vecteur `x` de taille `N_max` suivant la loi uniforme $\mathcal{U}([0, 1])$.
2. Représenter l'histogramme des valeurs observées X_i .
3. Pour chaque valeur `n` de `grid`, calculer les grandeurs empiriques associées au préfixe $(X_1, \dots, X_n)$:

Notation	Nom	Formule	Remarque
$\bar{X}_n$ ou $\hat{\mu}$	Moyenne empirique	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$	Estime l'espérance $\mathbb{E}[X] = \mu$.
s_n^2	Variance empirique (diviseur n)	$s_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$	Version « naïve » (souvent biaisée pour $\text{Var}(X) = \sigma^2$).
$\hat{s}_n^2$	Variance d'échantillon non biaisée (diviseur $n - 1$)	$\hat{s}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$	Estimateur non biaisé de $\text{Var}(X) = \sigma^2$ (sous i.i.d.).

4. Rappeler les valeurs théoriques de la moyenne μ et de la variance σ^2 de $\mathcal{U}([0, 1])$, puis comparer graphiquement les quantités empiriques à ces valeurs.
5. À quelle vitesse la moyenne empirique $\bar{X}_n$ converge-t-elle vers μ ? Proposer une illustration graphique (par exemple en traçant $|\bar{X}_n - \mu|$ en fonction de n et en comparant à une décroissance en $1/\sqrt{n}$, ou en traçant $\sqrt{n}|\bar{X}_n - \mu|$).

La densité empirique sur notre tirage de grande taille montre bien une quasi-équirépartition des valeurs (Figure 1). Notre loi empirique n'est pas parfaitement uniforme mais n'est pas loin de l'être à vue d'oeil. Avant d'étudier plus amplement la distribution, objet des prochains exercices, on peut déjà vérifier les moments de notre tirage que sont la moyenne et la variance empirique.





Figure 1. – Distribution empirique de notre tirage aléatoire de loi uniforme (question 2, Tip 1)

Avec la Figure 2, on voit la convergence de la moyenne empirique vers sa valeur théorique (l'espérance).




(a) Echelle normale

(b) Echelle logarithmique

Figure 2. – Convergence de la moyenne vers l'espérance théorique (question 3, Tip 1)

Avec la Figure 3 on voit que la version intuitive de la variance empirique, c'est-à-dire celle avec n au dénominateur, tend à systématiquement sous-estimer la variance. Il s'agit en effet d'un estimateur biaisé, même si celui-ci tend vers 0 à mesurer que n croît. La variance d'échantillon, celle avec $n - 1$, suit globalement la même dynamique mais se rapproche plus tôt de la valeur théorique.

Estimation de la variance de $\mathcal{U}([0, 1])$



```
/__w/python-datascientist/python-datascientist/.venv/lib/python3.13/site-packages/plotnine/geoms/geom_path.py:100: PlotnineWarning: geom_path: Removed 115 rows containing missing values.
```

Estimation de la variance de $\mathcal{U}([0, 1])$





Figure 3. – Convergence de la variance empirique vers la variance théorique (question 3, Tip 1)

Regardons la différence, en valeur absolue, entre μ et $\hat{\mu}$ pour essayer de déterminer la vitesse de convergence. Faisons ceci pour les premières valeurs, celles avant que l'erreur d'estimation soit minime.

```
/__w/python-datascientist/python-datascientist/.venv/lib/python3.13/site-packages/plotnine/geoms/geom_path.py:100: PlotnineWarning: geom_path: Removed 170 rows containing missing values.
/__w/python-datascientist/python-datascientist/.venv/lib/python3.13/site-packages/plotnine/geoms/geom_path.py:100: PlotnineWarning: geom_path: Removed 170 rows containing missing values.
```



Cela ressemble à une hyperbole du type $1/\sqrt{n}$. Vérifions si cela est cohérent en représentant $|\bar{X}_n - \mu|/\sqrt{n}$. Si on représente, au-delà des premières valeurs, le rapport entre l'erreur d'estimation et $\sqrt{n}$ (Figure 4), on voit que l'intuition précédente était correcte. On a bien une erreur d'estimation qui oscille autour de $1/\sqrt{n}$.




Figure 4. – Représentation de l'erreur d'estimation et son lien avec le nombre d'observations

5.2 Distribution de résultats de lancer de pièces

💡 Exercice 6, partie 2. Moivre-Laplace (binomiale)

On considère une suite i.i.d. $(X_i)_{i \geq 1}$ telle que $X_i \sim \mathcal{B}(100, 1/2)$ (nombre de piles sur 100 lancers d'une pièce équilibrée).

1. Représenter graphiquement la loi de X_1 (fonction de masse) : $k \mapsto \mathbb{P}(X_1 = k)$ pour $k \in \{0, \dots, 100\}$.
2. Calculer la moyenne $\mu = \mathbb{E}[X_1]$ et la variance $\sigma^2 = \text{Var}(X_1)$. Donner leurs valeurs numériques.
3. Pour une valeur N (par exemple $N \in \{50, 200, 1000, 5000\}$), générer $X_1, \dots, X_N$ i.i.d. et calculer $\bar{X}_N = \frac{1}{N} \sum_{i=1}^N X_i$.
4. En répétant l'expérience un grand nombre de fois, représenter la distribution empirique de

$$Y_N = \sqrt{N} (\bar{X}_N - \mu).$$

5. Sur la même figure, superposer la densité de la loi normale $\mathcal{N}(0, \sigma^2)$. Dans ce cas, on doit obtenir $\sigma^2 = 25$.

💡 Exercice 6, partie 3. TCL pour d'autres lois (variance finie)

Choisir une loi parmi : Poisson, exponentielle, uniforme (au choix), en précisant ses paramètres. On considère une suite i.i.d. $(X_i)_{i \geq 1}$ suivant cette loi, de moyenne μ et variance σ^2 (finies).

1. Donner (ou calculer) μ et σ^2 pour la loi choisie.
2. Pour plusieurs valeurs de N , en répétant l'expérience un grand nombre de fois, représenter la distribution empirique de

$$Y_N = \sqrt{N} (\bar{X}_N - \mu)$$

et la comparer à la densité de la loi normale $\mathcal{N}(0, \sigma^2)$.

3. Option : étudier aussi la version standardisée

$$Z_N = \sqrt{N} \frac{\bar{X}_N - \mu}{\sigma}$$

et la comparer à $\mathcal{N}(0, 1)$.

💡 Exercice 6, partie 4. Contre-exemple : loi de Cauchy

On considère maintenant une suite i.i.d. $(X_i)_{i \geq 1}$ suivant une loi de Cauchy standard.

1. Générer un vecteur `x` de taille `N_max` suivant une loi de Cauchy standard.
2. Pour chaque valeur n de `grid`, calculer la moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ et tracer $\bar{X}_n$ en fonction de n .
3. Le comportement observé ressemble-t-il à une convergence vers une constante ? Comparer qualitativement avec la partie 1.
4. La LGN et le TCL « classiques » s'appliquent-ils ici ? Justifier en discutant l'existence (ou non) de μ et de σ^2 .

6 Broadcasting

Le *broadcasting* désigne un ensemble de règles permettant d'appliquer des opérations sur des tableaux de dimensions différentes. En pratique, cela consiste généralement à appliquer une seule opération à l'ensemble des membres d'un tableau `numpy`.

La différence peut être comprise à partir de l'exemple suivant. Le *broadcasting* permet de transformer le scalaire 5 en *array* de dimension 3:

```
a = np.array([0, 1, 2])
b = np.array([5, 5, 5])

a + b
a + 5
```

```
array([5, 6, 7])
```

Le *broadcasting* peut être très pratique pour effectuer de manière efficace des opérations sur des données à la structure complexe. Pour plus de détails, se rendre [ici](#) ou [ici](#).

6.1 Une application: programmer ses propres k-nearest neighbors

💡 Exercice 6 (un peu plus corsé)


1. Créer `X` un tableau à deux dimensions (i.e. une matrice) comportant 10 lignes et 2 colonnes. Les nombres dans le tableau sont aléatoires.
2. Importer le module `matplotlib.pyplot` sous le nom `plt`. Utiliser `plt.scatter` pour représenter les données sous forme de nuage de points.
3. Construire une matrice 10x10 stockant, à l'élément (i, j) , la distance euclidienne entre les points $X[i, :]$ et $X[j, :]$. Pour cela, il va falloir jouer avec les dimensions en créant des tableaux emboîtés à partir par des appels à `np.newaxis` :
 1. En premier lieu, utiliser `X1 = X[:, np.newaxis, :]` pour transformer la matrice en tableau emboîté. Vérifier les dimensions
 2. Créer `x2` de dimension `(1, 10, 2)` à partir de la même logique
 3. En déduire, pour chaque point, la distance avec les autres points pour chaque coordonnées. Elever celle-ci au carré
 4. A ce stade, vous devriez avoir un tableau de dimension `(10, 10, 2)`. La réduction à une matrice s'obtient en sommant sur le dernier axe. Regarder dans l'aide de `np.sum` comme effectuer une somme sur le dernier axe.
 5. Enfin, appliquer la racine carrée pour obtenir une distance euclidienne en bonne et due forme.
4. Vérifier que les termes diagonaux sont bien nuls (distance d'un point à lui-même...)
5. Il s'agit maintenant de classer, pour chaque point, les points dont les valeurs sont les plus similaires. Utiliser `np.argsort` pour obtenir, pour chaque ligne, le classement des points les plus proches
6. On va s'intéresser aux k-plus proches voisins. Pour le moment, fixons `k=2`. Utiliser `argpartition` pour réordonner chaque ligne de manière à avoir les 2 plus proches voisins de chaque point d'abord et le reste de la ligne ensuite
7. Utiliser le morceau de code ci-dessous

```
plt.scatter(X[:, 0], X[:, 1], s=100)


# draw lines from each point to its two nearest neighbors
K = 2
```

```
for i in range(X.shape[0]):
    for j in nearest_partition[i, :K+1]:
        # plot a line from X[i] to X[j]
        # use some zip magic to make it happen:
        plt.plot(*zip(X[j], X[i]), color='black')
```

Pour la question 2, vous devriez obtenir un graphique ayant cet aspect



Le résultat de la question 7 est le suivant :



Ai-je inventé cet exercice corsé ? Pas du tout, il vient de l'ouvrage *Python Data Science Handbook*. Mais, si je vous l'avais indiqué immédiatement, auriez-vous cherché à répondre aux questions ?

Par ailleurs, il ne serait pas une bonne idée de généraliser cet algorithme à de grosses données. La complexité de notre approche est $O(N^2)$. L'algorithme implémenté par `Scikit-Learn` est en $O[N \log N]$.

De plus, le calcul de distances matricielles en utilisant la puissance des cartes graphiques serait plus rapide. A cet égard, la librairie `faiss` ou les *frameworks* spécialisés dans le calcul de distance

entre des vecteurs à haute dimension comme [ChromaDB](#) offrent des performances beaucoup plus satisfaisantes que celles que permettraient [Numpy](#) sur ce problème précis.

7 Exercices supplémentaires

💡 Comprendre le principe de l'algorithme PageRank

[Google](#) est devenu célèbre grâce à son algorithme [PageRank](#). Celui-ci permet, à partir de liens entre sites *web*, de donner un score d'importance à un site *web* qui va être utilisé pour évaluer sa centralité dans un réseau. L'objectif de cet exercice est d'utiliser [Numpy](#) pour mettre en oeuvre un tel algorithme à partir d'une matrice d'adjacence qui relie les sites entre eux.


1. Créer la matrice suivante avec [Numpy](#). L'appeler **M**:

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 1 \\ 0.5 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0.5 & 0 & 0 \\ 0 & 0 & 0.5 & 1 & 0 \end{bmatrix}$$

2. Pour représenter visuellement ce *web* minimaliste, convertir en objet [networkx](#) (une librairie spécialisée dans l'analyse de réseau) et utiliser la fonction [draw](#) de ce package.

Il s'agit de la transposée de la matrice d'adjacence qui permet de relier les sites entre eux. Par exemple, le site 1 (première colonne) est référencé par les sites 2 et 3. Celui-ci ne référence que le site 5.

3. A partir de la page wikipedia anglaise de [PageRank](#), tester sur votre matrice.



Le site 1 est assez central car il est référencé 2 fois. Le site 5 est lui également central puisqu'il est référencé par le site 1.

```
array([[0.25419178],  
       [0.13803151],  
       [0.13803151],  
       [0.20599017],  
       [0.26375504]])
```

Informations additionnelles

i Environnement Python

Ce site a été construit automatiquement par le biais d'une action [Github](#) utilisant le logiciel de publication reproductible [Quarto](#) (version 1.10.18).

L'environnement utilisé pour obtenir les résultats est reproductible par le biais d'[uv](#). Le fichier [pyproject.toml](#) utilisé pour construire cet environnement est disponible sur le dépôt [linogaliana/python-datascientist](#)

```
[project]  
name = "python-datascientist"  
version = "0.1.0"  
description = "Source code for Lino Galiana's Python for data science course"  
readme = "README.md"  
requires-python = "≥3.13,<3.14"  
dependencies = [  
    "altair≥6.0.0",  
    "cartiflette",  
    "contextily=1.6.2",  
    "duckdb≥0.10.1",  
    "folium≥0.19.6",  
    "gdal=3.11.4",  
    "graphviz=0.20.3",  
    "great-tables≥0.12.0",  
    "gt-extras≥0.0.8",  
    "ipykernel≥6.29.5",  
    "jupyter≥1.1.1",  
    "jupyter-cache≥1.0.0",  
    "kaleido≥0.2.1",  
    "langchain-community≥0.3.27",  
    "loguru=0.7.3",  
    "markdown≥3.8",  
    "nbclient≥0.10.0",  
    "nbformat≥5.10.4",  
    "nltk≥3.9.1",  
    "pandas≥3.0",  
    "pip≥25.1.1",  
    "plotly≥6.1.2",  
    "plotnine≥0.15",  
    "polars≥1.8.2",  
    "pyarrow≥17.0.0",  
    "pynsee≥0.1.8",  
    "python-dotenv≥1.0.1",  
    "python-frontmatter≥1.1.0",  
    "pywaffle≥1.1.1",  
    "requests≥2.32.3",  
    "scikit-image≥0.24.0",
```

```
"scikit-learn ≥ 1.8.0",
"scipy ≥ 1.13.0",
"seaborn ≥ 0.13.2",
"selenium < 4.39.0",
"spacy ≥ 3.8.4",
"webdriver-manager ≥ 4.0.2",
"wordcloud = 1.9.3",
]

[tool.uv.sources]
cartiflette = { git = "https://github.com/insee-fr/lab/cartiflette" }
gdal = [
    { index = "gdal-wheels", marker = "sys_platform == 'linux'", },
    { index = "geospatial-wheels", marker = "sys_platform == 'win32'", },
]

[[tool.uv.index]]
name = "geospatial-wheels"
url = "https://nathanjmcougall.github.io/geospatial-wheels-index/"
explicit = true

[[tool.uv.index]]
name = "gdal-wheels"
url = "https://gitlab.com/api/v4/projects/61637378/packages/pypi/simple"
explicit = true

[dependency-groups]
dev = [
    "nb-clean ≥ 4.0.1",
]
```

Pour utiliser exactement le même environnement (version de `Python` et `packages`), se reporter à la documentation d'`uv`.