

Introduction à Pandas

Lino Galiana

Version du 29 septembre 2026

Pandas est l'élément central de l'écosystème **Python** pour la *data science*. Ce chapitre présente les premières manipulations de données qu'on peut faire grâce à **Pandas** pour explorer la structure de son jeu de données.

⚠ PDF généré automatiquement. Ce document est produit à partir du site du cours et peut présenter des problèmes de mise en forme. Pour une version à jour et adaptée à la lecture, consultez la page du cours : pythonands.linogaliana.fr.

Table des matières

1 Introduction	2
1.1 Données	2
1.2 Environnement	2
2 Logique de Pandas	3
2.1 Anatomie d'une table Pandas	3
2.2 Avant le DataFrame, la Serie	4
3 De la Serie au DataFrame	5
3.1 L'indexation	6
3.2 Le concept de <i>tidy data</i>	6
4 Importer des données avec Pandas	7
4.1 Lire des données depuis un chemin local	8
4.2 Lecture depuis un CSV disponible sur internet	8
5 Explorer la structure d'un DataFrame	9
5.1 Dimensions et structure d'un DataFrame	10
5.2 Accéder à des éléments d'un DataFrame	11
5.3 Accéder à des lignes	11
6 Principales manipulations de données	12
6.1 Opérations sur les colonnes : ajouter ou retirer des variables, les renommer, etc.	13
6.2 Réordonner les observations	14
6.3 Filter	15
6.4 Résumé des principales opérations	16
7 Statistiques descriptives	16
7.1 Comptages	17
7.2 Statistiques agrégées	18
7.3 Valeurs manquantes	20
8 Représentations graphiques rapides	23
9 Exercice de synthèse	25
Références	28
Informations additionnelles	28
Bibliographie	29

💡 Compétences à l'issue de ce chapitre

- Importer un jeu de données sous forme de *dataframe* **Pandas** et explorer sa structure ;
- Effectuer des manipulations sur les colonnes et les lignes ;
- Construire des statistiques agrégées et chaîner les opérations ;

- Utiliser les méthodes graphiques de **Pandas** pour se représenter rapidement la distribution des données.

1 Introduction

Le *package* **Pandas** est l'une des briques centrales de l'écosystème de la *data science* depuis une dizaine d'années. Le *DataFrame*, objet central dans des langages comme **R** ou **Stata**, a longtemps été un grand absent dans l'écosystème **Python**. Pourtant, grâce à **Numpy**, toutes les briques de base étaient présentes mais méritaient d'être réagencées pour convenir aux besoins des *data scientists*.

Wes McKinney, lorsqu'il a construit **Pandas** pour proposer un *dataframe* s'appuyant, en arrière-plan, sur la librairie de calcul numérique **Numpy**, a permis un grand bond en avant pour **Python** dans l'analyse de données qui explique sa popularité dans l'écosystème de la *data science*. **Pandas** n'est pas sans limite¹, nous aurons l'occasion d'en évoquer quelques unes, mais la grande richesse des méthodes d'analyses proposées simplifie énormément le travail d'analyse de données. Pour en savoir plus sur ce *package*, l'ouvrage de référence de W. McKinney [1] présente de nombreuses fonctionnalités du *package*.

Nous nous concentrerons dans ce chapitre sur les éléments les plus pertinents dans le cadre d'une introduction à la *data science* et laisserons les utilisateurs intéressés approfondir leurs connaissances dans les ressources foisonnantes qu'il existe sur le sujet.

Comme les jeux de données prennent généralement de la valeur en associant plusieurs sources, par exemple pour mettre en relation un enregistrement avec une donnée contextuelle ou pour lier deux bases clients afin d'avoir une donnée faisant sens, le chapitre suivant présentera la manière d'associer des jeux de données différents avec **Pandas**. A l'issue du chapitre suivant, grâce à des croisements de données, nous disposerons d'une base fine sur les empreintes carbone des Français².

1.1 Données

Dans ce tutoriel **Pandas**, nous allons utiliser :

- Les émissions de gaz à effet de serre estimées au niveau communal par l'ADEME. Le jeu de données est disponible sur [data.gouv](https://data.gouv.fr) et requêtable directement dans **Python** avec [cet url](#) ;

Le [chapitre suivant](#) permettra de mettre en application des éléments présents dans ce chapitre avec les données ci-dessus associées à des données de contexte au niveau communal.

1.2 Environnement

Nous suivrons les conventions habituelles dans l'import des packages :

¹L'écosystème équivalent en **R**, le **tidyverse**, développé par *Posit*, est de conception plus récente que **Pandas**. Sa philosophie a ainsi pu s'inspirer de celle de **Pandas** tout en pouvant remédier à quelques limites de la syntaxe **Pandas**. Les deux syntaxes étant une mise en oeuvre en **Python** ou **R** de la philosophie **SQL**, il est naturel qu'elles se ressemblent beaucoup et qu'il soit pertinent pour les *data scientists* de connaître les deux langages.

²A vrai dire, ce n'est pas l'empreinte carbone mais l'**inventaire national** puisque la base de données correspond à une vision production, pas consommation. Les émissions faites dans une commune pour satisfaire la consommation d'une autre seront imputées à la première là où le concept d'empreinte carbone voudrait qu'on l'impute aux secondes. De plus, les émissions présentées ici ne comportent pas les émissions produites par des biais produits à l'étranger. Il ne s'agit pas, avec cet exercice, de construire une statistique fiable mais plutôt de comprendre la logique de l'association de données pour construire des statistiques descriptives.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

Pour obtenir des résultats reproductibles, on peut fixer la racine du générateur pseudo-aléatoire.

```
np.random.seed(123)
```

Au cours de cette démonstration des principales fonctionnalités de **Pandas**, et lors du chapitre suivant, je recommande de se référer régulièrement aux ressources suivantes :

- L'[aide officielle de Pandas](#). Notamment, la [page de comparaison des langages](#) qui est très utile ;
- [Ce tutoriel](#), pensé certes pour les utilisateurs d'[Observable Javascript](#), mais qui offre de nombreux exemples intéressants pour les aficionados de **Pandas** ;
- La [cheatsheet suivante](#), [issue de ce post](#)

Pour rappel, afin d'exécuter les exemples de code dans un *notebook* interactif, vous pouvez utiliser les raccourcis en haut de la page pour lancer celui-ci dans votre environnement de prédilection.

2 Logique de Pandas

2.1 Anatomie d'une table Pandas

L'objet central dans la logique **Pandas** est le **DataFrame**. Il s'agit d'une structure particulière de données à deux dimensions, structurées en alignant des lignes et colonnes. Contrairement à une matrice, les colonnes peuvent être de types différents.

Un **DataFrame** est composé des éléments suivants :

- l'indice de la ligne ;
- le nom de la colonne ;
- la valeur de la donnée ;

	Mountain	Height (m)	Range	Coordinates	Parent mountain	First ascent	Ascents bef. 2004	Failed attempts bef. 2004
0	Mount Everest / Sagarmatha / Chomolungma	8848	Mahalangur Himalaya	27°59'17"N 86°55'31"E	NaN	1953	>>145	121.0
1	K2 / Qogir / Godwin Austen	8611	Baltoro Karakoram	35°52'53"N 76°30'48"E	Mount Everest	1954	45	44.0
2	Kangchenjunga	8586	Kangchenjunga Himalaya	27°42'12"N 88°08'51"E	Mount Everest	1955	38	24.0
3	Lhotse	8516	Mahalangur Himalaya	27°57'42"N 86°55'59"E	Mount Everest	1956	26	26.0
4	Makalu	8485	Mahalangur Himalaya	27°53'23"N 87°05'20"E	Mount Everest	1955	45	52.0
5	Cho Oyu	8188	Mahalangur Himalaya	28°05'39"N 86°39'39"E	Mount Everest	1954	79	28.0
6	Dhaulagiri I	8167	Dhaulagiri Himalaya	28°41'48"N 83°29'35"E	K2	1960	51	39.0
7	Manaslu	8163	Manaslu Himalaya	28°33'00"N 84°33'35"E	Cho Oyu	1956	49	45.0
8	Nanga Parbat	8126	Nanga Parbat Himalaya	35°14'14"N 74°35'21"E	Dhaulagiri	1953	52	67.0
9	Annapurna I	8091	Annapurna Himalaya	28°35'44"N 83°49'13"E	Cho Oyu	1950	36	47.0

Figure 1. – Structuration d'un **DataFrame Pandas**, empruntée à https://x.com/epfl_exts/status/997506000600084480

2.2 Avant le `DataFrame`, la `Serie`

En fait, un `DataFrame` est une collection d'objets appelés `pandas.Series`. Ces `Serie`s sont des objets d'une dimension qui sont des extensions des array-unidimensionnels `Numpy`³. En particulier, pour faciliter le traitement de données catégorielles ou temporelles, des types de variables supplémentaires sont disponibles dans `Pandas` par rapport à `Numpy` (`categorical`, `datetime64` et `timedelta64`). Ces types sont associés à des méthodes optimisées pour faciliter le traitement de ces données.

Il existe plusieurs types possibles pour un `pandas.Series`, extension des types de données de base en `Python` qui détermineront ensuite le comportement de cette variable. En effet, de nombreuses opérations n'ont pas le même sens selon qu'on a une valeur numérique ou non.

Les types les plus simples (`int` ou `float`) correspondent aux valeurs numériques:

```
poids = pd.Series(  
    [3, 7, 12]  
)  
poids
```

```
0    3  
1    7  
2   12  
dtype: int64
```

! Attention aux valeurs manquantes !

De manière générale, si `Pandas` détecte exclusivement des valeurs entières dans une variable, il utilisera le type `int` pour optimiser la mémoire. Ce choix fait sens. Il a néanmoins un inconvénient: `Numpy`, et donc par extension `Pandas`, ne sait se représenter des valeurs manquantes pour le type `int` (plus d'éléments sur les valeurs manquantes ci-dessous).

En attendant le changement de couche basse en faveur d'`Arrow`, qui lui sait gérer les valeurs manquantes dans les `int`, la méthode à mettre en oeuvre est de convertir au type `float` si la variable sera amenée à avoir des valeurs manquantes, ce qui est assez simple:

Pour des données textuelles, c'est tout aussi simple:

```
animal = pd.Series(  
    ['chat', 'chien', 'koala']  
)  
animal
```

```
0    chat  
1   chien  
2   koala  
dtype: str
```

Depuis `Pandas` 3.0, les données exclusivement textuelles reçoivent nativement le type dédié `str`, comme on le voit ci-dessus : ce n'est plus le type `object` qui est utilisé par défaut pour du texte. Le type `object` reste une voiture-balais, mais il est désormais réservé aux données réellement

³L'objectif originel de `Pandas` est de fournir une librairie haut-niveau vers des couches basses plus abstraites que sont les `array Numpy`. `Pandas` est progressivement en train de changer ces couches basses pour privilégier `Arrow` à `Numpy` sans déstabiliser les commandes haut-niveau auxquelles les utilisateurs de `Pandas` sont habitués. Ce changement s'explique par le fait qu'`Arrow`, une librairie bas niveau de calcul, est plus puissante et plus flexible que `Numpy`. Cette dernière, par exemple, propose des types textuels limités là où `Arrow` offre une plus grande liberté.

mélangées (texte et nombres, ou objets Python arbitraires, type `mixed`). Historiquement, `object` jouait le rôle d'intermédiaire entre le `factor` et le `character` de R ; ce rôle est maintenant mieux assuré par la distinction `str/category`. Il existe en effet un type équivalent au `factor` de R dans Pandas, le type `category`, à privilégier lorsque la variable ne prend qu'un nombre fini et relativement restreint de valeurs (avec, à la clé, des gains de mémoire et de performance). Il est donc recommandé, lorsqu'on désire se concentrer sur une variable textuelle à faible cardinalité, de la convertir explicitement :

```
animal.astype("category")
animal.astype(str)
```

Ligne 1

Pour convertir en `category` (le choix qui fait sens ici)

Ligne 2

Pour repasser en `str` explicitement (redondant ici puisque c'est déjà le type par défaut depuis Pandas 3.0, mais utile si la colonne provient d'un import ayant forcé un typage `object`)

```
0    chat
1    chien
2    koala
dtype: str
```

Il faut bien examiner les types de ses objets Pandas et les convertir s'ils ne font pas sens ; Pandas fait certes des choix optimisés mais il est parfois nécessaire de les corriger car Pandas ne connaît pas vos usages ultérieurs des données. C'est l'une des opérations à faire lors du *feature engineering*, ensemble des étapes de préparation des données pour un usage ultérieur.

3 De la Serie au DataFrame

Nous avons créé deux séries indépendantes, `animal` et `poids` qui sont pourtant reliées. Dans le monde matriciel, cela correspondrait à passer du vecteur à la matrice. Dans le monde de Pandas, cela veut dire passer de la *Serie* au *DataFrame*.

Cela se fait naturellement avec Pandas:

```
animaux = pd.DataFrame(
    zip(animal, poids),
    columns = ['animal', 'poids']
)
animaux
```

	animal	poids
0	chat	3
1	chien	7
2	koala	12

1. On doit utiliser `zip` ici car Pandas attend une structure du type `{"var1": [val1, val2], "var2": [val1, val2]}` qui n'est pas celle que nous avons préparé précédemment. Nous verrons néanmoins que cette approche n'est pas la plus usuelle pour créer un *DataFrame*

3.1 L'indexation

La différence essentielle entre une `Series` et un objet `Numpy` est l'indexation. Dans `Numpy`, l'indexation est implicite ; elle permet d'accéder à une donnée (celle à l'index situé à la position i). Avec une `Series`, on peut bien sûr utiliser un indice de position mais on peut surtout faire appel à des indices plus explicites.

Ceci permet d'accéder à la donnée de manière plus naturelle, en utilisant les noms de colonne par exemple:

```
animaux['poids']
```

```
0    3
1    7
2   12
Name: poids, dtype: int64
```

L'existence d'indice rend le *subsetting*, c'est-à-dire la sélection de lignes ou de colonnes, particulièrement aisé. Les `DataFrames` pendant présentent deux indices: ceux des lignes et ceux des colonnes. On pourra faire des sélections sur ces deux dimensions. En anticipant sur les exercices ultérieurs, on peut voir que cela va nous faciliter la sélection de ligne:

```
animaux.loc[animaux['animal'] == "chat", 'poids']
```

```
0    3
Name: poids, dtype: int64
```

Cette instruction est équivalente à la commande `SQL`:

```
SELECT poids FROM animaux WHERE animal = "chat"
```

Si on revient sur notre jeu de données `animaux`, on peut voir sur la gauche l'affichage du numéro de la ligne:

```
animaux
```

	animal	poids
0	chat	3
1	chien	7
2	koala	12

Il s'agit de l'indice par défaut pour la dimension ligne car nous n'en n'avons pas configuré un. Ce n'est pas obligatoire, il est tout à fait possible d'avoir un indice correspondant à une variable d'intérêt (nous découvrirons cela lorsque nous explorerons `groupby` dans le prochain chapitre). Cependant, cela peut être piégeux et il est recommandé que cela ne soit que transitoire, d'où l'intérêt de faire régulièrement des `reset_index`.

3.2 Le concept de *tidy data*

Le concept de *tidy data*, popularisé par Hadley Wickham via ses packages `R` (voir H. Wickham, M. Çetinkaya-Rundel, et G. Grolemund [2]), est parfaitement pertinent pour décrire la structure d'un `DataFrame Pandas`. Les trois règles des données *tidy* sont les suivantes :

- Chaque **variable** possède sa propre colonne ;
- Chaque **observation** possède sa propre ligne ;
- Une **valeur**, matérialisant une observation d'une variable, se trouve sur une unique cellule.




Figure 2. – Illustration du concept de *tidy data* (emprunté à H. Wickham)

Ces principes peuvent vous apparaître de bon sens mais vous découvrirez que de nombreux formats de données ne correspondent pas à ce principe. Par exemple, des tableurs Excel proposent régulièrement des valeurs à cheval sur plusieurs colonnes ou plusieurs lignes fusionnées. Restructurer cette donnée selon le principe des *tidy data* sera un enjeu pour être en mesure d'effectuer des traitements sur celle-ci.

4 Importer des données avec Pandas

S'il fallait créer à la main tous ses *DataFrames* à partir de vecteurs, **Pandas** ne serait pas pratique. **Pandas** propose de nombreuses fonctions pour lire des données stockées dans des formats différents.

Les données les plus simples à lire sont les données tabulaires stockées dans un format adéquat. Les deux principaux formats à connaître sont le **CSV** et le format **Parquet**. Le premier présente l'avantage de la simplicité - il est universel, connu de tous et est lisible par n'importe quel éditeur de texte. Le second gagne en popularité dans l'écosystème de la donnée, car il règle certaines limites du CSV (stockage optimisé, types des variables prédéfinis...) mais présente l'inconvénient de ne pas être lisible sans un outil adéquat (qui heureusement sont de plus en plus présents dans les éditeurs de code standard comme **VSCode**). Pour en savoir plus sur la différence entre **CSV** et **Parquet**, se reporter aux [chapitre d'approfondissement](#) sur le sujet.

Les données stockées dans les autres formats textes dérivés du **CSV** (**.txt**, **.tsv**...) ou les formats type **JSON** sont lisibles avec **Pandas** mais il faut parfois itérer pour trouver les bons paramètres de lecture. Nous découvrirons dans d'autres chapitres que d'autres formats de données liés à des structures de données différentes sont tout aussi lisibles avec **Python**.

Les formats plats (**.csv**, **.txt**...) et le format **Parquet** sont simples à utiliser avec **Pandas** parce que d'une part ils ne sont pas propriétaires et d'autre part ils stockent la donnée sous une forme *tidy*. Les données issues de tableurs, **Excel** ou **LibreOffice**, sont plus ou moins compliquées à importer selon qu'elles suivent ce schéma ou non. Cela vient du fait que ces outils sont utilisés à tort et à travers. Alors que dans le monde de la *data science* ceux-ci devraient servir principalement à diffuser des tableaux finaux pour du *reporting*, ils servent souvent à diffuser une donnée brute qui pourrait l'être par des canaux plus adaptés. L'une des principales difficultés liées aux tableurs vient du fait que les données sont généralement associées à de la documentation dans le même onglet - par exemple le tableau comporte quelques lignes décrivant les sources avant le tableau - ce qui nécessite de l'intelligence humaine pour assister **Pandas** lors de la phase d'import. Celle-ci sera toujours possible mais lorsqu'il existe une alternative sous forme de fichier plat, il n'y a pas d'hésitation à avoir.

4.1 Lire des données depuis un chemin local

Cet exercice vise à présenter l'intérêt d'utiliser un chemin relatif plutôt qu'un chemin absolu pour favoriser la reproductibilité du code. Nous préconiserons néanmoins par la suite de privilégier directement la lecture depuis internet lorsqu'elle est possible et n'implique pas le téléchargement récurrent d'un fichier volumineux.

Pour préparer cet exercice, le code suivant permettra de télécharger des données qu'on va écrire en local

```
import requests

url = "https://www.insee.fr/fr/statistiques/fichier/6800675/v_commune_2023.csv"
url_backup = "https://minio.lab.sspcloud.fr/lgaliana/data/python-ENSAE/cog_2023.csv"

try:
    response = requests.get(url)
except requests.exceptions.RequestException as e:
    print(f"Error : {e}")
    response = requests.get(url_backup)

# Only download if one of the request succeeded
if response.status_code == 200:
    with open("cog_2023.csv", "wb") as file:
        file.write(response.content)
```

💡 Exercice préliminaire: Importer un CSV (optionnel)

1. Utiliser le code ci-dessus 🙌 pour télécharger les données. Utiliser **Pandas** pour lire le fichier téléchargé.
2. Chercher où les données ont été écrites. Observer la structure de ce dossier.
3. Créer un dossier depuis l'explorateur de fichiers (à gauche dans **Jupyter** ou **VSCode**). Déplacer le CSV et le *notebook*. Redémarrer le kernel et adaptez votre code si besoin. Refaire cette manipulation plusieurs fois avec des dossiers différents. Quel peut être le problème rencontré ?

	TYPECOM	COM	REG	DEP	CTCD	ARR	TNCC	NCC	NCCENR	LIBELLE	CAN	COMPARENT
0	COM	01001	84.0	01	01D	012	5	ABERGEMENT CLEMENCIAT	Abergement-Clémenciat	L'Abergement-Clémenciat	0108	NaN
1	COM	01002	84.0	01	01D	011	5	ABERGEMENT DE VAREY	Abergement-de-Varey	L'Abergement-de-Varey	0101	NaN

Le principal problème de la lecture depuis des fichiers stockés en local est le risque de se rendre adhérent à un système de fichier qui n'est pas forcément partagé. Il vaut mieux, lorsque c'est possible, directement lire la donnée avec un lien **HTTPS**, ce que **Pandas** sait faire. De plus, lorsqu'on travaille sur de l'*open data* cela assure qu'on utilise la dernière donnée disponible et non une duplication en local qui peut ne pas être à jour.

4.2 Lecture depuis un CSV disponible sur internet

L'URL d'accès aux données peut être conservé dans une variable *ad hoc* :

```
url = "https://koumoul.com/s/data-fair/api/v1/datasets/igt-pouvoir-de-rechauffement-global/convert"
```

L'objectif du prochain exercice est de se familiariser à l'import et l'affichage de données avec **Pandas** et à l'affichage de quelques observations.

💡 Exercice 1: Importer un CSV et explorer la structure de données

1. Importer les données de l'Ademe à l'aide du package `Pandas` et de la commande consacrée pour l'import de csv. Nommer le `DataFrame` obtenu `emissions`⁴.
2. Utiliser les méthodes adéquates afin d'afficher pour les 10 premières valeurs, les 15 dernières et un échantillon aléatoire de 10 valeurs grâce aux méthodes adéquates du `package Pandas`.
3. Tirer 5 pourcents de l'échantillon sans remise.
4. Ne conserver que les 10 premières lignes et tirer aléatoirement dans celles-ci pour obtenir un `DataFrame` de 100 données.
5. Faire 100 tirages à partir des 6 premières lignes avec une probabilité de 1/2 pour la première observation et une probabilité uniforme pour les autres.

En cas de blocage à la question 1 Lire la documentation de `read_csv` (très bien faite) ou chercher des exemples en ligne pour découvrir cette fonction.

Comme l'illustre cet exercice, l'affichage des `DataFrames` dans les *notebooks* est assez ergonomique. Les premières et dernières lignes s'affichent automatiquement. Pour des tables de valorisation présentes dans un rapport ou un article de recherche, le chapitre suivant présente `great_tables` qui offre de très riches fonctionnalités de mise en forme des tableaux.

⚠ Warning

Il faut faire attention au `display` et aux commandes qui révèlent des données (`head`, `tail`, etc.) dans un *notebook* qui exploite des données confidentielles lorsqu'on utilise le logiciel de contrôle de version `Git` (cf. chapitres dédiés).

En effet, on peut se retrouver à partager des données, involontairement, dans l'historique `Git`. Comme cela sera expliqué dans le chapitre dédié à `Git`, un fichier, nommé le `.gitignore`, suffit pour créer quelques règles évitant le partage involontaire de données avec `Git`.

5 Explorer la structure d'un *DataFrame*

`Pandas` propose donc un schéma de données assez familier aux utilisateurs de logiciels statistiques comme `R`. A l'instar des principaux paradigmes de traitement de la données comme le *tidyverse* (`R`), la grammaire de `Pandas` est héritière de la logique `SQL`. La philosophie est très proche : on effectue des opérations de sélection de ligne, de colonne, des tris de ligne en fonction de valeurs de certaines colonnes, des traitements standardisés sur des variables, etc. De manière générale, on privilégie les traitements faisant appel à des noms de variables à des numéros de ligne ou de colonne.

Que vous soyez familiers de `SQL` ou de `R`, vous retrouverez une logique similaire à celle que vous connaissez quoique les noms puissent diverger: `df.loc[df['y']=='b']` s'écrit peut-être `df %>% filter(y=='b')` (`R`) ou `SELECT * FROM df WHERE y = 'b'` (`SQL`) mais la logique est la même.

`Pandas` propose énormément de fonctionnalités pré-implémentées. Il est vivement recommandé, avant de se lancer dans l'écriture d'une fonction, de se poser la question de son implémentation native dans `Numpy`, `Pandas`, etc. La plupart du temps, s'il existe une solution implémentée dans une librairie, il convient de l'utiliser car elle sera plus efficace que celle que vous mettrez en oeuvre.

⁴Par manque d'imagination, on est souvent tenté d'appeler notre *dataframe* principal `df` ou `data`. C'est souvent une mauvaise idée puisque ce nom n'est pas très informatif quand on relit le code quelques semaines plus tard. L'autodocumentation, approche qui consiste à avoir un code qui se comprend de lui-même, est une bonne pratique et il est donc recommandé de donner un nom simple mais efficace pour connaître la nature du *dataset* en question.

Pour présenter les méthodes les plus pratiques pour l'analyse de données, on peut partir de l'exemple des consommations de CO2 communales issues des données de l'Ademe auquel les exercices précédents étaient dédiés.

```
df = pd.read_csv("https://koumoul.com/s/data-fair/api/v1/datasets/igt-pouvoir-de-rechauffement-global/convert")
df
```

	INSEE commune	Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire
0	01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172
1	01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207
2	01004	AMBERIEU-EN-BUGEY	499.043526	212.577908	NaN	10313.446515	5314.314445	998.332482	2930.354461	16616.822534	15642.420313	10732.376934
3	01005	AMBERIEUX-EN-DOMBES	1859.160954	NaN	NaN	1144.429311	216.217508	94.182310	276.448534	663.683146	1756.341319	782.404357
4	01006	AMBLEON	448.966808	NaN	NaN	77.033834	48.401549	NaN	NaN	43.714019	398.786800	51.681756
...	...	...	...	...	...	...	...	...	...	...	...	...
35793	95676	VILLERS-EN-ARTHIES	1628.065094	NaN	NaN	165.045396	65.063617	11.772789	34.556067	176.098160	309.627908	235.439109
35794	95678	VILLERS-ADAM	698.630772	NaN	NaN	1331.126598	111.480954	2.354558	6.911213	1395.529811	18759.370071	403.404815
35795	95680	VILLIERS-LE-BEL	107.564967	NaN	NaN	8367.174532	225.622903	534.484607	1568.845431	22613.830247	12217.122402	13849.512001
35796	95682	VILLIERS-LE-SEC	1090.890170	NaN	NaN	326.748418	108.969749	2.354558	6.911213	67.235487	4663.232127	85.657725
35797	95690	WY-DIT-JOLI-VILLAGE	1495.103542	NaN	NaN	125.236417	97.728612	4.709115	13.822427	117.450851	504.400972	147.867245

5.1 Dimensions et structure d'un *DataFrame*

Les premières méthodes utiles permettent d'afficher quelques attributs d'un *DataFrame*.

```
df.axes
```

```
[RangeIndex(start=0, stop=35798, step=1),
 Index(['INSEE commune', 'Commune', 'Agriculture', 'Autres transports',
        'Autres transports international', 'CO2 biomasse hors-total', 'Déchets',
        'Energie', 'Industrie hors-énergie', 'Résidentiel', 'Routier',
        'Tertiaire'],
        dtype='str')]
```

```
df.columns
```

```
Index(['INSEE commune', 'Commune', 'Agriculture', 'Autres transports',
        'Autres transports international', 'CO2 biomasse hors-total', 'Déchets',
        'Energie', 'Industrie hors-énergie', 'Résidentiel', 'Routier',
        'Tertiaire'],
        dtype='str')
```

```
df.index
```

```
RangeIndex(start=0, stop=35798, step=1)
```

Pour connaître les dimensions d'un *DataFrame*, on peut utiliser quelques méthodes pratiques :

```
df.ndim
```

```
2
```

```
df.shape
```

```
(35798, 12)
```

```
df.size
```

```
429576
```

Pour déterminer le nombre de valeurs uniques d'une variable, plutôt que chercher à écrire soi-même une fonction, on utilise la méthode `nunique`. Par exemple,

```
df['Commune'].nunique()
```

```
33338
```

`Pandas` propose énormément de méthodes utiles. Voici un premier résumé de celles relatives à la structure des données, accompagné d'un comparatif avec `R` :

Opération	pandas	dplyr (R)
Récupérer le nom des colonnes	<code>df.columns</code>	<code>colnames(df)</code>
Récupérer les dimensions	<code>df.shape</code>	<code>dim(df)</code>
Récupérer le nombre de valeurs uniques d'une variable	<code>df['myvar'].nunique()</code>	<code>df %>% summarise(distinct(myvar))</code>

5.2 Accéder à des éléments d'un DataFrame

En SQL, effectuer des opérations sur les colonnes se fait avec la commande `SELECT`. Avec `Pandas`, pour accéder à une colonne dans son ensemble on peut utiliser plusieurs approches :

- `dataframe.variable`, par exemple `df.Energie`. Cette méthode requiert néanmoins d'avoir des noms de colonnes sans espace ou caractères spéciaux, ce qui exclut souvent des jeux de données réels. Elle n'est pas recommandée. ;
- `dataframe[['variable']]` pour renvoyer la variable sous forme de `DataFrame`. Cette méthode peut être assez piègeuse pour une variable seule, il vaut mieux lui privilégier `dataframe.loc[:, ['variable']]` qui est plus explicite sur la nature de l'objet qu'on désire en sortie ;
- `dataframe['variable']` pour renvoyer la variable sous forme de `Series`. Par exemple, `df[['Autres transports']]` ou `df['Autres transports']`. C'est une manière préférable de procéder.

Pour récupérer plusieurs colonnes à la fois, il y a deux approches, la seconde étant préférable :

- `dataframe[['variable1', 'variable2']]` ;
- `dataframe.loc[:, ['variable1', 'variable2']]`

Cela est équivalent à `SELECT variable1, variable2 FROM dataframe` en SQL.

Le `.loc` peut apparaître excessivement verbeux. Il permet néanmoins de s'assurer qu'on effectue bien un *subset* sur la dimension des colonnes. Les `DataFrame` ayant deux indices, ceux des lignes et des colonnes, on peut avoir parfois des surprises avec l'implicite, il est plus fiable d'être explicite.

5.3 Accéder à des lignes

Pour accéder à une ou plusieurs valeurs d'un `DataFrame`, il existe deux manières conseillées de procéder, selon la forme des indices de lignes ou colonnes utilisées :

- `df.iloc` : utilise les indices. C'est une méthode moyennement fiable car les indices d'un *DataFrame* peuvent évoluer au cours d'un traitement (notamment lorsqu'on fait des opérations par groupe).
- `df.loc` : utilise les labels. Cette méthode est recommandée.

⚠ Warning

Les bouts de code utilisant la structure `df.ix` sont à bannir car la fonction est *deprecated* et peut ainsi disparaître à tout moment.

`iloc` va se référer à l'indexation de 0 à N où N est égal à `df.shape[0]` d'un `pandas.DataFrame`. `loc` va se référer aux valeurs de l'index de `df`. Par exemple, avec le `pandas.DataFrame` `df_example`:

```
df_example = pd.DataFrame(
    {'month': [1, 4, 7, 10], 'year': [2012, 2014, 2013, 2014], 'sale': [55, 40, 84, 31]}
)
df_example = df_example.set_index('month')
df_example
```

	year	sale
month		
1	2012	55
4	2014	40
7	2013	84
10	2014	31

- `df_example.loc[1, :]` donnera la première ligne de `df` (ligne où l'indice `month` est égal à 1) ;
- `df_example.iloc[1, :]` donnera la deuxième ligne (puisque l'indexation en *Python* commence à 0) ;
- `df_example.iloc[:, 1]` donnera la deuxième colonne, suivant le même principe.

Les exercices ultérieurs permettront de pratiquer cette syntaxe sur notre jeu de données des émissions de gaz carbonique.

6 Principales manipulations de données

Les opérations les plus fréquentes en *SQL* sont résumées par le tableau suivant. Il est utile de les connaître (beaucoup de syntaxes de maniement de données reprennent ces termes) car, d'une manière ou d'une autre, elles couvrent la plupart des usages de manipulation des données. Nous allons en décrire, par la suite, quelques unes:

Opération	SQL	pandas	dplyr (R)
Sélectionner des variables par leur nom	<code>SELECT</code>	<code>df.loc[:, ['Autres transdf %>% select(Autres transports, Energie)</code>	
Sélectionner des observations selon une ou	<code>FILTER</code>	<code>df.loc[pd.col('Agricult df %>% filter(Agriculture>2000)</code>	

Opération	SQL	pandas	dplyr (R)
plusieurs conditions;			
Trier la table selon une ou plusieurs variables	<code>SORT BY</code>	<code>df.sort_values(['Commune', 'Agriculture'])</code>	<code>arrange(Commune, Agriculture)</code>
Ajouter des variables qui sont fonction d'autres variables;	<code>SELECT *, LOG(Agriculture) AS x FROM df</code>	<code>df = df.assign(x = np.log(df['Agriculture']))</code>	

Les prochains chapitres nous permettront d'aller plus loin en ajoutant d'autres opérations plus complexes (jointures, statistiques par groupes, etc.)

6.1 Opérations sur les colonnes : ajouter ou retirer des variables, les renommer, etc.

Sur le plan technique, les `DataFrames Pandas` sont des objets *mutables* en langage `Python`, c'est-à-dire qu'il est possible de faire évoluer le `DataFrame` au grès des opérations mises en oeuvre.

L'opération la plus classique consiste à ajouter ou retirer des variables à la table de données. La manière la plus simple d'opérer pour ajouter des colonnes est d'utiliser la réaffectation. Par exemple, pour créer une variable `dep` qui correspond aux deux premiers numéros du code commune (code Insee), il suffit de prendre la variable et lui appliquer le traitement adapté (en l'occurrence ne garder que ses deux premières caractères):

```
df['dep'] = df['INSEE commune'].str[:2]
df.head(3)
```

	INSEE commune	Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep
0	01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172	01
1	01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207	01
2	01004	AMBERIEU-EN-BUGEY	499.043526	212.577908	NaN	10313.446515	5314.314445	998.332482	2930.354461	16616.822534	15642.420313	10732.376934	01

En SQL, la manière de procéder dépend du moteur d'exécution. En pseudo-code cela donne

```
SELECT everything(), SUBSTR("code_insee", 2) AS dep FROM df
```

Il est possible d'appliquer cette approche de création de colonnes sur plusieurs colonnes. Un des intérêts de cette approche est qu'elle permet de recycler le nom de colonnes.

```
vars = ['Agriculture', 'Déchets', 'Energie']

df[[v + "_log" for v in vars]] = np.log(df.loc[:, vars])
df.head(3)
```

	INSEE commune	Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep	Agriculture_log	Déchets_log	Energie_log
0	01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172	01	8.219171	4.619374	0.856353
1	01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207	01	6.164010	4.946455	0.856353
2	01004	AMBERIEU-EN-BUGEY	499.043526	212.577908	NaN	10313.446515	5314.314445	998.332482	2930.354461	16616.822534	15642.420313	10732.376934	01	6.212693	8.578159	6.906086

La requête équivalente en SQL serait assez fastidieuse à écrire. Sur ce genre d'opérations, on voit bien l'intérêt d'avoir une librairie haut niveau comme **Pandas**.

⚠ Warning

Cela est possible grâce à la vectorisation native des opérations de **Numpy** et à la magie **Pandas** qui réarrange tout ceci. Ce n'est pas utilisable avec n'importe quelle fonction. Pour d'autres fonctions, il faudra utiliser **assign**, généralement par le biais de *lambda functions*, des fonctions temporaires faisant office de passe plat. Par exemple, pour créer une variable selon cette approche, il faudrait faire:

```
df.assign(
    Energie_log = lambda x: np.log(x['Energie'])
)
```

Depuis **Pandas** 3.0, **pd.col** permet d'éviter la *lambda function* tout en restant dans **assign** :

```
df.assign(
    Energie_log = np.log(pd.col('Energie'))
)
```

Avec des méthodes de **Pandas** ou de **Numpy** comme ici, cela n'a pas d'intérêt, c'est même contre-productif car cela ralentit le code.

On peut facilement renommer des variables avec la méthode **rename** qui fonctionne bien avec des dictionnaires. Pour renommer des colonnes il faut préciser le paramètre **axis = 'columns'** ou **axis=1**. Le paramètre **axis** est souvent nécessaire car par défaut de nombreuses méthodes de **Pandas** supposent que l'indice sur lequel les opérations sont faites est l'indice des lignes :

```
df = df.rename({"Energie": "eneg", "Agriculture": "agr"}, axis=1)
df.head()
```

INSEE commune	Commune	agr	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	eneg	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep	Agriculture_log	Déchets_log	Energie_log
0 01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172	01	8.219171	4.619374	0.856353
1 01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207	01	6.164010	4.946455	0.856353
2 01004	AMBERIEU-EN-BUGEY	499.043526	212.577908	NaN	10313.446515	5314.314445	998.332482	2930.354461	16616.822534	15642.420313	10732.376934	01	6.212693	8.578159	6.906086
3 01005	AMBERIEUX-EN-DOBRES	1859.160954	NaN	NaN	1144.429311	216.217508	94.182310	276.448534	663.683146	1756.341319	782.404357	01	7.527881	5.376285	4.545232
4 01006	AMBLEON	448.966808	NaN	NaN	77.033834	48.401549	NaN	NaN	43.714019	398.786800	51.681756	01	6.106949	3.879532	NaN

Enfin, pour effacer des colonnes, on utilise la méthode **drop** avec l'argument **columns**:

```
df = df.drop(columns = ["eneg", "agr"])
df.head()
```

6.2 Réordonner les observations

La méthode **sort_values** permet de réordonner les observations d'un **DataFrame**, en laissant l'ordre des colonnes identiques.

Par exemple, si on désire classer par ordre décroissant de consommation de CO2 du secteur résidentiel, on fera

```
df = df.sort_values("Résidentiel", ascending = False)
df.head(3)
```

INSEE commune	Commune	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep	Agriculture_log	Déchets_log	Energie_log
12167 31555	TOULOUSE	4482.980062	130.792683	576394.181208	88863.732538	277062.573234	410675.902028	586054.672836	288175.400126	31	7.268255	11.394859	11.424640
16774 44109	NANTES	138738.544337	250814.701179	193478.248177	18162.261628	77897.138554	354259.013785	221068.632724	173447.582779	44	5.513507	9.807101	9.767748
27294 67482	STRASBOURG	124998.576639	122266.944279	253079.442156	119203.251573	135685.440035	353586.424577	279544.852332	179562.761386	67	6.641974	11.688585	9.885411

Ainsi, en une ligne de code, on identifie les villes où le secteur résidentiel consomme le plus. En SQL on ferait

```
SELECT * FROM df ORDER BY DESC "Résidentiel"
```

6.3 Filter

L'opération de sélection de lignes s'appelle **FILTER** en SQL. Elle s'utilise en fonction d'une condition logique (clause **WHERE**). On sélectionne les données sur une condition logique.

Il existe plusieurs méthodes en **Pandas**. La plus simple est d'utiliser les *boolean mask*, déjà vus dans le chapitre **numpy**.

Par exemple, pour sélectionner les communes dans les Hauts-de-Seine, on peut commencer par utiliser le résultat de la méthode **str.startswith** (qui renvoie **True** ou **False**) :

```
df['INSEE commune'].str.startswith("92")
```

```
12167    False
16774    False
27294    False
12729    False
22834    False
...
20742    False
20817    False
20861    False
20898    False
20957    False
Name: INSEE commune, Length: 35798, dtype: bool
```

str. est une méthode particulière en **Pandas** qui permet de traiter chaque valeur d'un vecteur comme un **string** natif en **Python** sur lequel appliquer une méthode ultérieure (en l'occurrence **startswith**).

L'instruction ci-dessus renvoie un vecteur de booléens. Nous avons vu précédemment que la méthode **loc** servait à faire du *subsetting* sur l'indice des lignes comme des colonnes. Elle fonctionne avec des vecteurs booléens. Dans ce cas, si on fait un *subsetting* sur la dimension ligne (resp. colonne), elle va renvoyer toutes les observations (resp. variable) qui satisfont cette condition.

Ainsi, en mettant bout à bout ces deux éléments, on peut filter nos données pour n'avoir que les résultats du 92:

```
df.loc[df['INSEE commune'].str.startswith("92")].head(2)
```

INSEE commune	Commune	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep	Agriculture_log	Déchets_log	Energie_log
35494 92012	BOULOGNE-BILLANCOURT	1250.483441	34.234669	51730.704250	964.828694	25882.493998	92216.971456	64985.280901	60349.109482	92	NaN	6.871951	9.084530
35501 92025	COLOMBES	411.371588	14.220061	53923.847088	698.685861	50244.664227	87469.549463	52070.927943	41526.600867	92	NaN	6.549201	9.461557

Depuis **Pandas** 3.0, il existe une notation alternative, **pd.col**, qui permet de désigner une colonne sans répéter le nom du **DataFrame**. Elle est à privilégier car elle rend le code plus lisible et plus facile à chaîner (elle se rapproche de la notation **pl.col** de **Polars**) :

```
df.loc[pd.col('INSEE commune').str.startswith("92")].head(2)
```

INSEE commune	Commune	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Industrie hors-énergie	Résidentiel	Routier	Tertiaire	dep	Agriculture_log	Déchets_log	Energie_log
35494 92012	BOULOGNE-BILLANCOURT	1250.483441	34.234669	51730.704250	964.828694	25882.493998	92216.971456	64985.280901	60349.109482	92	NaN	6.871951	9.084530
35501 92025	COLOMBES	411.371588	14.220061	53923.847088	698.685861	50244.664227	87469.549463	52070.927943	41526.600867	92	NaN	6.549201	9.461557

Le code SQL équivalent peu varier selon le moteur d'exécution ([DuckDB](#), [PostGre](#), [MySQL](#)) mais prendrait une forme similaire à celle-ci:

```
SELECT * FROM df WHERE STARTSWITH("INSEE commune", "92")
```

6.4 Résumé des principales opérations

Les principales manipulations sont les suivantes:




Fig. 1. – Réordonner le *DataFrame*

7 Statistiques descriptives

Pour repartir de la source brute, recréons notre jeu de données pour les exemples:

```
df = pd.read_csv("https://koumoul.com/s/data-fair/api/v1/datasets/igt-pouvoir-de-rechauffement-global/convert")
df.head(3)
```

	INSEE commune	Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire
0	01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172
1	01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207

Pandas embarque plusieurs méthodes pour construire des statistiques agrégées: somme, nombre de valeurs unique, nombre de valeurs non manquantes, moyenne, variance, etc.

La méthode la plus générique est **describe**

```
df.describe()
```

	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire
count	35736.000000	9979.000000	2.891000e+03	35798.000000	35792.000000	3.449000e+04	3.449000e+04	35792.000000	35778.000000	35798.000000
mean	2459.975760	654.919940	7.692345e+03	1774.381550	410.806329	6.625698e+02	2.423128e+03	1783.677872	3535.501245	1105.165915
std	2926.957701	9232.816833	1.137643e+05	7871.341922	4122.472608	2.645571e+04	5.670374e+04	8915.902379	9663.156628	5164.182507
min	0.003432	0.000204	3.972950e-04	3.758088	0.132243	2.354558e+00	1.052998e+00	1.027266	0.555092	0.000000
25%	797.682631	52.560412	1.005097e+01	197.951108	25.655166	2.354558e+00	6.911213e+00	96.052911	419.700460	94.749885
50%	1559.381285	106.795928	1.992434e+01	424.849988	54.748653	4.709115e+00	1.382243e+01	227.091193	1070.895593	216.297718
75%	3007.883903	237.341501	3.298311e+01	1094.749825	110.820941	5.180027e+01	1.520467e+02	749.469293	3098.612157	576.155869
max	98949.317760	513140.971691	3.303394e+06	576394.181208	275500.374439	2.535858e+06	6.765119e+06	410675.902028	586054.672836	288175.400126

qui ressemble à la méthode éponyme en **Stata** ou à la **PROC FREQ** de **SAS**, deux langages propriétaires. Elle nous donne néanmoins beaucoup d'information et on est souvent noyé par celle-ci. Il est donc plus pratique de directement travailler sur quelques colonnes ou de choisir soi-même les statistiques qu'on désire utiliser.

7.1 Comptages

Le premier type de statistiques qu'on peut vouloir mettre en oeuvre relève du comptage ou dénombrement des valeurs.

Si on désire, par exemple, connaître le nombre de communes dans notre jeu de données, on pourra utiliser la méthode **count** ou alors **unique** si on s'intéresse aux valeurs non dupliquées.

```
df['Commune'].count()
```

```
np.int64(35798)
```

```
df['Commune'].nunique()
```

```
33338
```

En SQL, la première instruction serait **SELECT COUNT(Commune) FROM df**, la seconde **SELECT COUNT DISTINCT Commune FROM df**. Ici, cela ne permet donc de comprendre qu'il peut y avoir des doublons dans la colonne **Commune**, ce dont il faudra tenir compte si on désire identifier nos communes de manière unique (ce sera un sujet lorsque le prochain chapitre abordera la question du croisement des données).

La cohérence de la syntaxe **Pandas** permet de faire cela pour plusieurs colonnes de manière simultanée. En SQL cela serait possible mais le code à mettre en oeuvre commence à devenir assez verbeux:

```
df.loc[:, ['Commune', 'INSEE commune']].count()
```

```
Commune      35798
INSEE commune 35798
dtype: int64
```

```
df.loc[:, ['Commune', 'INSEE commune']].nunique()
```

```
Commune      33338
INSEE commune 35798
dtype: int64
```

Avec ces deux commandes simples, on comprend donc que notre variable `INSEE commune` (le code Insee) sera plus fiable pour identifier des communes que les noms, qui ne sont pas forcément uniques. C'est justement l'objectif du code Insee de proposer un identifiant unique, a contrario du code postal qui peut être partagé par plusieurs communes.

7.2 Statistiques agrégées

`Pandas` embarque plusieurs méthodes pour construire des statistiques sur plusieurs colonnes: somme, moyenne, variance, etc.

Les méthodes sont assez transparentes:

```
df['Agriculture'].sum()
df['Agriculture'].mean()
```

```
np.float64(2459.975759687974)
```

Là encore, la cohérence de `Pandas` nous permet de généraliser le calcul de statistiques à plusieurs colonnes

```
df.loc[:, ['Agriculture', 'Résidentiel']].sum()
df.loc[:, ['Agriculture', 'Résidentiel']].mean()
```

```
Agriculture      2459.975760
Résidentiel      1783.677872
dtype: float64
```

Il est possible de généraliser ceci à toutes les colonnes. Cependant, il est nécessaire d'introduire le paramètre `numeric_only` pour ne faire la tâche d'agrégation que sur les variables pertinentes

```
df.mean(numeric_only = True)
```

```
Agriculture      2459.975760
Autres transports      654.919940
Autres transports international      7692.344960
CO2 biomasse hors-total      1774.381550
Déchets      410.806329
Energie      662.569846
Industrie hors-énergie      2423.127789
Résidentiel      1783.677872
Routier      3535.501245
Tertiaire      1105.165915
dtype: float64
```

⚠ Warning

La version 2.0 de `Pandas` a introduit un changement de comportement dans les méthodes d'agrégation.

Il est dorénavant nécessaire de préciser quand on désire effectuer des opérations si on désire ou non le faire exclusivement sur les colonnes numériques. C'est pour cette raison qu'on explicite ici l'argument `numeric_only = True`. Ce comportement était par le passé implicite.

La méthode pratique à connaître est `agg`. Celle-ci permet de définir les statistiques qu'on désire calculer pour chaque variable

```
df.agg(
    {
        'Agriculture': ['sum', 'mean'],
        'Résidentiel': ['mean', 'std'],
        'Commune': 'nunique'
    }
)
```

	Agriculture	Résidentiel	Commune
sum	8.790969e+07	NaN	NaN
mean	2.459976e+03	1783.677872	NaN
std	NaN	8915.902379	NaN
nunique	NaN	NaN	33338.0

La sortie des méthodes d'agrégation est une `Serie` indexée (les méthodes du type `df.sum()`) ou directement un `DataFrame` (la méthode `agg`). Il est en général plus pratique d'avoir un `DataFrame` qu'une `Serie` indexée si on désire retravailler le tableau pour en tirer des conclusions. Il est donc utile de transformer les sorties sous forme de `Serie` en `DataFrame` puis appliquer la méthode `reset_index` pour transformer l'indice en colonne. A partir de là, il sera possible de modifier le `DataFrame` pour rendre celui-ci plus lisible.

Par exemple si on s'intéresse à la part de chaque secteur dans les émissions totales, on pourra procéder en deux temps. D'abord on va créer une observation par secteur représentant les émissions totales de celui-ci:

```
# Etape 1: création d'un DataFrame propre
emissions_totales = (
    pd.DataFrame(
        df.sum(numeric_only = True),
        columns = ["emissions"]
    )
    .reset_index(names = "secteur")
)
emissions_totales
```

	secteur	emissions
0	Agriculture	8.790969e+07
1	Autres transports	6.535446e+06
2	Autres transports international	2.223857e+07
3	CO2 biomasse hors-total	6.351931e+07
4	Déchets	1.470358e+07
5	Energie	2.285203e+07
6	Industrie hors-énergie	8.357368e+07
7	Résidentiel	6.384140e+07

	secteur	emissions
8	Routier	1.264932e+08
9	Tertiaire	3.956273e+07

Il ne reste plus qu'à travailler *a minima* le jeu de données afin d'avoir déjà quelques conclusions intéressantes sur la structure des émissions en France:

```
emissions_totales['emissions (%)'] = (
    100*emissions_totales['emissions']/emissions_totales['emissions'].sum()
)
(emissions_totales
 .sort_values("emissions", ascending = False).
 round()
)
```

	secteur	emissions	emissions (%)
8	Routier	126493164.0	24.0
0	Agriculture	87909694.0	17.0
6	Industrie hors-énergie	83573677.0	16.0
7	Résidentiel	63841398.0	12.0
3	CO2 biomasse hors-total	63519311.0	12.0
9	Tertiaire	39562729.0	7.0
5	Energie	22852034.0	4.0
2	Autres transports international	22238569.0	4.0
4	Déchets	14703580.0	3.0
1	Autres transports	6535446.0	1.0

Ce tableau n'est pas vraiment mis en forme donc encore loin d'être communicable mais il présente déjà un intérêt dans une perspective exploratoire. Il nous permet de comprendre les secteurs les plus émetteurs, à savoir le transport, l'agriculture et l'industrie, hors énergie. Le fait que l'énergie soit relativement peu émettrice s'explique bien du fait du *mix énergétique* français où le nucléaire représente une majorité de la production électrique.

Pour aller plus loin dans la mise en forme de ce tableau afin d'avoir des statistiques communicables en dehors de `Python`, nous découvrirons au prochain chapitre `great_tables`.

i Note

La structure de données issue de `df.sum` est assez pratique (elle est *tidy*). On pourrait faire exactement la même opération que `df.sum(numeric_only = True)` avec le code suivant:

```
df.select_dtypes(include='number').agg(func = sum)
```

7.3 Valeurs manquantes

Jusqu'à présent nous n'avons pas évoqué ce qui pourrait être un caillou dans la chaussure du *data scientist*, les valeurs manquantes.

Les jeux de données réels sont rarement complets et les valeurs manquantes peuvent refléter de nombreuses réalités: problème de remontée d'information, variable non pertinente pour cette observation...

Sur le plan technique, **Pandas** ne rencontre pas de problème à gérer les valeurs manquantes (sauf pour les variables `int` mais c'est une exception). Par défaut, les valeurs manquantes sont affichées `NaN` et sont de type `np.nan` (pour les valeurs temporelles, i.e. de type `datetime64`, les valeurs manquantes sont `NaT`). On a un comportement cohérent d'agrégation lorsqu'on combine deux colonnes dont l'une comporte des valeurs manquantes.

```
import numpy as np
rng = np.random.default_rng()

ventes = pd.DataFrame(
    {'prix': rng.uniform(size = 5),
     'client1': [i+1 for i in range(5)],
     'client2': [i+1 for i in range(4)] + [np.nan],
     'produit': [np.nan] + ['yaourt', 'pates', 'riz', 'tomates']}
)
ventes
```

	prix	client1	client2	produit
0	0.791263	1	1.0	NaN
1	0.395354	2	2.0	yaourt
2	0.381866	3	3.0	pates
3	0.806432	4	4.0	riz
4	0.342810	5	NaN	tomates

Pandas va bien refuser de faire l'agrégation car pour lui une valeur manquante n'est pas un zéro:

```
ventes["client1"] + ventes["client2"]
```

```
0    2.0
1    4.0
2    6.0
3    8.0
4    NaN
dtype: float64
```

Il est possible de supprimer les valeurs manquantes grâce à `dropna()`. Cette méthode va supprimer toutes les lignes où il y a au moins une valeur manquante.

```
ventes.dropna()
```

	prix	client1	client2	produit
1	0.395354	2	2.0	yaourt
2	0.381866	3	3.0	pates
3	0.806432	4	4.0	riz

En l'occurrence, on perd deux lignes. Il est aussi possible de supprimer seulement les colonnes où il y a des valeurs manquantes dans un DataFrame avec `dropna()` en utilisant le paramètre `subset`.

```
ventes.dropna(subset=["produit"])
```

	prix	client1	client2	produit
1	0.395354	2	2.0	yaourt
2	0.381866	3	3.0	pates
3	0.806432	4	4.0	riz
4	0.342810	5	NaN	tomates

Cette fois on ne perd plus qu'une ligne, celle où `produit` est manquant.

`Pandas` donne la possibilité d'imputer les valeurs manquantes grâce à la méthode `fillna()`. Par exemple, si on pense que les valeurs manquantes dans `produit` sont des valeurs nulles, on pourra faire

```
ventes.dropna(subset=["produit"]).fillna(0)
```

	prix	client1	client2	produit
1	0.395354	2	2.0	yaourt
2	0.381866	3	3.0	pates
3	0.806432	4	4.0	riz
4	0.342810	5	0.0	tomates

Si on désire faire une imputation à la médiane pour la variable `client2`, on changera marginalement ce code en encapsulant à l'intérieur le calcul de la médiane

```
(ventes["client2"]
 .fillna(
     ventes["client2"].median()
 )
)
```

```
0    1.0
1    2.0
2    3.0
3    4.0
4    2.5
Name: client2, dtype: float64
```

Sur des jeux de données du monde réel, il est utile d'utiliser la méthode `isna` (ou `isnull`) combinées avec `sum` ou `mean` pour connaître l'ampleur des valeurs manquantes dans un jeu de données.

```
df.isnull().mean().sort_values(ascending = False)
```

```
Autres transports international    0.919241
Autres transports                  0.721241
Energie                           0.036538
Industrie hors-énergie             0.036538
Agriculture                       0.001732
Routier                           0.000559
Résidentiel                       0.000168
Déchets                           0.000168
INSEE commune                     0.000000
Commune                           0.000000
CO2 biomasse hors-total            0.000000
Tertiaire                         0.000000
dtype: float64
```

Cette étape préparatoire est utile pour anticiper la question de l'imputation ou du filtre sur les valeurs manquantes: sont-elles *missing at random* ou reflètent-elles un sujet sur la remontée des données ? Les choix relatifs au traitement des valeurs manquantes ne sont pas des choix méthodologiques neutres. **Pandas** donne les outils techniques pour faire ceci mais la question de la légitimité de ces choix et de la pertinence est propre à chaque donnée. Les explorations sur les données visent à détecter des indices pour faire un choix éclairé.


8 Représentations graphiques rapides

Les tableaux de nombre sont certes une information utile pour comprendre la structure d'un jeu de données mais dont l'aspect dense rend l'appropriation difficile. Avoir un graphique simplement peut être utile pour se représenter, en un coup d'oeil, la distribution des données et ainsi connaître le caractère plus ou moins normal d'une observation.

Pandas embarque des méthodes graphiques rudimentaires pour répondre à ce besoin. Elles sont pratiques pour produire rapidement un graphique, notamment après des opérations complexes de maniement de données. Nous approfondirons cette problématique des visualisations de données dans la partie [Communiquer](#).


On peut appliquer la méthode `plot()` directement à une **Serie** :

```
df['Déchets'].plot()
```




Le code équivalent avec **matplotlib** serait:

```
import matplotlib.pyplot as plt
plt.plot(df.index, df['Déchets'])
```




Par défaut, la visualisation obtenue est une série. Ce n'est pas forcément celle attendue puisqu'elle n'a de sens que pour des séries temporelles. En tant que *data scientist* sur microdonnées, on s'intéresse plus fréquemment à un histogramme pour avoir une idée de la distribution des données. Pour cela, il suffit d'ajouter l'argument `kind = 'hist'`:

```
df['Déchets'].hist()
```



Avec des données dont la distribution est non normalisée, ce qui représente de nombreuses variables du monde réel, les histogrammes sont généralement peu instructifs. Le *log* peut être une solution pour remettre à une échelle comparable certaines valeurs extrêmes:

```
df['Déchets'].plot(kind = 'hist', logy = True)
```



La sortie est un objet `matplotlib`. La *customisation* de ces figures est ainsi possible (et même désirable car les graphiques `matplotlib` sont, par défaut, assez rudimentaires). Cependant, il s'agit d'une méthode rapide pour la construction de figures qui nécessite du travail pour une visualisation finalisée. Cela passe par un travail approfondi sur l'objet `matplotlib` ou l'utilisation d'une librairie plus haut niveau pour la représentation graphique (`seaborn`, `plotnine`, `plotly`, etc.).

La partie de ce cours consacrée à la visualisation de données présentera succinctement ces différents paradigmes de visualisation. Ceux-ci ne dispensent pas de faire preuve de bon sens dans le choix du graphique utilisé pour représenter une statistique descriptive (cf. [cette conférence d'Eric Mauvière](#)).

9 Exercice de synthèse

Cette exercice synthétise plusieurs étapes de préparation et d'exploration de données pour mieux comprendre la structure du phénomène qu'on désire étudier à savoir les émissions de gaz carbonique en France.

Il est recommandé de repartir d'une session vierge (dans un *notebook* il faut faire `Restart Kernel`) pour ne pas avoir un environnement pollué par d'autres objets. Vous pouvez ensuite exécuter le code suivant pour avoir la base nécessaire:

```
import pandas as pd

emissions = pd.read_csv("https://koumoul.com/s/data-fair/api/v1/datasets/igt-pouvoir-de-rechauffement-global/convert")
emissions.head(2)
```

	INSEE commune	Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire
0	01001	L'ABERGEMENT-CLEMENCIAT	3711.425991	NaN	NaN	432.751835	101.430476	2.354558	6.911213	309.358195	793.156501	367.036172
1	01002	L'ABERGEMENT-DE-VAREY	475.330205	NaN	NaN	140.741660	140.675439	2.354558	6.911213	104.866444	348.997893	112.934207

💡 Exercice 2: Découverte des verbes de Pandas pour manipuler des données

En premier lieu, on propose de se familiariser avec les opérations sur les colonnes.

1. Créer un `dataframe` `emissions_copy` ne conservant que les colonnes `INSEE commune`, `Commune`, `Autres transports` et `Autres transports international`

$$df.loc[:, ['x', 'z']]$$

x	y	z	x	z

Indice pour cette question

2. Comme les noms de variables sont peu pratiques, les renommer de la manière suivante :

- `INSEE commune` → `code_insee`
- `Autres transports` → `transports`
- `Autres transports international` → `transports_international`

$$df.rename({'y': 'a'}, axis = 1)$$

x	y	z	x	a	z

Indice pour cette question

3. On propose, pour simplifier, de remplacer les valeurs manquantes (`NA`) par la valeur 0. Utiliser la méthode `fillna` pour transformer les valeurs manquantes en 0.
4. Créer les variables suivantes :
 - `dep`: le département. Celui-ci peut être créé grâce aux deux premiers caractères de `code_insee` en appliquant la méthode `str` ;
 - `transports_total`: les émissions du secteur transports (somme des deux variables)

$$df['a'] = df['x'] + df['y']$$

x	y	z	x	y	z	a

Indice pour cette question

5. Ordonner les données du plus gros pollueur au plus petit puis ordonner les données du plus gros pollueur au plus petit par département (du 01 au 95).

Indice

pour

cette


$$df.sort_values('y', ascending = False)$$

x	y	z	x	y	z
a			c		
b			a		
c			b		

question

6. Ne conserver que les communes appartenant aux départements 13 ou 31. Ordonner ces communes du plus gros pollueur au plus petit.

```
df.loc[df['y']==b]
```



Indice pour cette question

Revenir au jeu `emission` initial

- 7. Calculer les émissions totales par secteur. Calculer la part de chaque secteur dans les émissions totales. Transformer en tonnes les volumes avant d’afficher les résultats
- 8. Calculer pour chaque commune les émissions totales après avoir imputé les valeurs manquantes à 0. Garder les 100 communes les plus émettrices. Calculer la part de chaque secteur dans cette émission. Comprendre les facteurs pouvant expliquer ce classement.

Aide si vous êtes en difficulté sur la question 8 Jouer avec le paramètre `axis` lors de la construction d’une statistique agrégée.

A la question 5, quand on ordonne les communes exclusivement à partir de la variable `transports_total`, on obtient ainsi:

	code_insee	Commune	transports	transports_international	dep	transports_total
31108	77291	LE MESNIL-AMELOT	133834.090767	3.303394e+06	77	3.437228e+06
31099	77282	MAUREGARD	133699.072712	3.303394e+06	77	3.437093e+06
31111	77294	MITRY-MORY	89815.529858	2.202275e+06	77	2.292090e+06

A la question 6, on obtient ce classement :

	code_insee	Commune	transports	transports_international	dep	transports_total
4438	13096	SAINTES-MARIES-DE-LA-MER	271182.758578	0.000000	13	271182.758578
4397	13054	MARIGNANE	245375.418650	527360.799265	13	772736.217915
11684	31069	BLAGNAC	210157.688544	403717.366279	31	613875.054823

A la question 7, le tableau obtenu ressemble à

	secteur	emissions	emissions (%)
2	transports_total	28774.0	50.0
1	transports_international	22239.0	39.0
0	transports	6535.0	11.0

INSEE commune		Commune	Agriculture	Autres transports	Autres transports international	CO2 biomasse hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Routier	Tertiaire
4382	13039	FOS-SUR-MER	305.092893	1893.383189	1.722723e+04	50891.367548	275500.374439	2.296711e+06	6.765119e+06	9466.388806	74631.401993	42068.140058
22671	59183	DUNKERQUE	811.390947	3859.548994	3.327586e+05	71922.181764	23851.780482	1.934988e+06	5.997333e+06	113441.727216	94337.865738	70245.678455
4398	13056	MARTIGUES	855.299300	2712.749275	3.043476e+04	35925.561051	44597.426397	1.363402e+06	2.380185e+06	22530.797276	84624.862481	44394.822725
30560	76476	PORT-JEROME-SUR-SEINE	2736.931327	121.160849	2.086403e+04	22846.964780	78.941581	1.570236e+06	2.005643e+06	21072.566129	9280.824961	15270.357772
31108	77291	LE MESNIL-AMELOT	782.183307	133834.090767	3.303394e+06	3330.404124	111.613197	8.240952e+02	2.418925e+03	1404.400153	11712.541682	13680.471909
...	...	...	...	...	...	...	...	...	...	...	...	...
30056	74281	THONON-LES-BAINS	382.591429	145.151526	0.000000e+00	144503.815623	21539.524775	2.776024e+03	1.942086e+05	44545.339492	25468.667604	19101.562585
33954	86194	POITIERS	2090.630127	20057.297403	2.183418e+04	95519.054766	13107.640015	5.771021e+03	1.693938e+04	110218.156827	91921.787626	73121.300634
1918	06019	BLAUSASC	194.382622	0.000000	0.000000e+00	978.840592	208.084792	2.260375e+02	4.362880e+05	538.816198	3949.838612	740.022785
27607	68253	OTTMARSHHEIM	506.238288	679.598495	3.526748e+01	4396.853500	237.508651	1.172570e+03	4.067258e+05	3220.875864	19317.977050	4921.144781
28643	71076	CHALON-SUR-SAONE	1344.584721	1336.547546	6.558180e+01	77082.218324	570.662275	1.016933e+04	2.075650e+05	77330.230592	29020.646500	34997.262920

A l'issue de la question 8, on comprend un peu mieux les facteurs qui peuvent expliquer une forte émission au niveau communal. Si on regarde les trois principales communes émettrices, on peut remarquer qu'il s'agit de villes avec des raffineries:

INSEE commune	Commune	Agriculture	Autres transports	Autres transports internationaux	CO2 Industrie hors-total	Déchets	Energie	Industrie hors-énergie	Résidentiel	Port Autres transports	Port Autres transports internationaux	Port CO2 Industrie hors-total	Port Déchets	Port Energie	Port Industrie hors-énergie	Port Résidentiel	Port Routes	Port Tourisme	Port total		
4382	13039	FOC-SE-B-AZER	365.092895	1895.953389	17227.254585	58891.367468	275589.974439	2.296714e+06	6.7651126e+06	9466.368806	...	0.019560	0.188886	0.515739	2.889719	24.095168	0.099205	0.762887	0.441252	108.0	
23671	59183	DENOUERQUE	811.390947	3819.548994	332758.630249	71022.181764	23811.788482	1.954986e+06	5.917332e+06	113441.727216	...	0.044652	3.840791	0.832891	0.279949	22.386499	65.385867	1.312484	1.091425	0.812495	108.0
4398	13056	MARTIGUES	838.295980	2712.740275	30434.762485	13925.361051	64597.626397	1.363482e+06	2.380105e+06	22530.792276	...	0.067655	0.759055	0.895975	1.112249	34.062905	59.361219	0.561912	2.110523	1.187196	108.0

Grâce à nos explorations minimales avec **Pandas**, on voit que ce jeu de données nous donne donc une information sur la nature du tissu productif français et des conséquences environnementales de certaines activités.

Références

- Le site [pandas.pydata](https://pandas.pydata.org/) fait office de référence
- Le livre **Modern Pandas** de Tom Augspurger : <https://tomaugspurger.github.io/modern-1-intro.html>

Informations additionnelles

i Environnement Python

Ce site a été construit automatiquement par le biais d'une action **GitHub** utilisant le logiciel de publication reproductible **Quarto** (version 1.10.18).

L'environnement utilisé pour obtenir les résultats est reproductible par le biais d'**uv**. Le fichier **pyproject.toml** utilisé pour construire cet environnement est disponible sur le dépôt [linogaliana/python-datascientist](https://github.com/linogaliana/python-datascientist)

```
[project]
name = "python-datascientist"
version = "0.1.0"
description = "Source code for Lino Galiana's Python for data science course"
readme = "README.md"
requires-python = "≥3.13,<3.14"
dependencies = [
    "altair≥6.0.0",
    "cartiflette",
    "contextily=1.6.2",
    "duckdb≥0.10.1",
    "folium≥0.19.6",
    "gdal=3.11.4",
    "graphviz=0.20.3",
    "great-tables≥0.12.0",
    "gt-extras≥0.0.8",
    "ipykernel≥6.29.5",
    "jupyter≥1.1.1",
    "jupyter-cache≥1.0.0",
    "kaleido≥0.2.1",
    "langchain-community≥0.3.27",
    "loguru=0.7.3",
    "markdown≥3.8",
    "nbclient≥0.10.0",
    "nbformat≥5.10.4",
```

```

    "nltk ≥ 3.9.1",
    "pandas ≥ 3.0",
    "pip ≥ 25.1.1",
    "plotly ≥ 6.1.2",
    "plotnine ≥ 0.15",
    "polars ≥ 1.8.2",
    "pyarrow ≥ 17.0.0",
    "pynsee ≥ 0.1.8",
    "python-dotenv ≥ 1.0.1",
    "python-frontmatter ≥ 1.1.0",
    "pywaffle ≥ 1.1.1",
    "requests ≥ 2.32.3",
    "scikit-image ≥ 0.24.0",
    "scikit-learn ≥ 1.8.0",
    "scipy ≥ 1.13.0",
    "seaborn ≥ 0.13.2",
    "selenium < 4.39.0",
    "spacy ≥ 3.8.4",
    "webdriver-manager ≥ 4.0.2",
    "wordcloud = 1.9.3",
]

[tool.uv.sources]
cartiflette = { git = "https://github.com/insee-fr/lab/cartiflette" }
gdal = [
    { index = "gdal-wheels", marker = "sys_platform == 'linux'" },
    { index = "geospatial-wheels", marker = "sys_platform == 'win32'" },
]

[[tool.uv.index]]
name = "geospatial_wheels"
url = "https://nathanjmcDougall.github.io/geospatial-wheels-index/"
explicit = true

[[tool.uv.index]]
name = "gdal-wheels"
url = "https://gitlab.com/api/v4/projects/61637378/packages/pypi/simple"
explicit = true

[dependency-groups]
dev = [
    "nb-clean ≥ 4.0.1",
]

```

Pour utiliser exactement le même environnement (version de **Python** et *packages*), se reporter à la documentation d'**uv**.

Bibliographie

- [1] W. McKinney, *Python for data analysis: Data wrangling with Pandas, NumPy, and IPython*. "O'Reilly Media, Inc.", 2012.

- [2] H. Wickham, M. Çetinkaya-Rundel, et G. Grolemund, *R for data science*. " O'Reilly Media, Inc.", 2023.