

Introduction à Pandas

Lino Galiana

Version du 29 septembre 2026

Pandas est l'élément central de l'écosystème **Python** pour la *data science*. Le succès récent de **Python** dans l'analyse de données tient beaucoup à **Pandas** qui a permis d'importer la logique **SQL** dans le langage **Python**. **Pandas** embarque énormément de fonctionnalités qui permettent d'avoir des chaînes de traitement efficaces pour traiter des données de volumétrie moyenne (jusqu'à quelques Gigas). Au-delà de cette volumétrie, il faudra se tourner vers d'autres solutions (**DuckDB**, **Dask**, **Polars**, **Spark**...).

⚠ **PDF généré automatiquement.** Ce document est produit à partir du site du cours et peut présenter des problèmes de mise en forme. Pour une version à jour et adaptée à la lecture, consultez la page du cours : pythonds.linogaliana.fr.

Table des matières

Informations additionnelles	1
Bibliographie	3

La partie **Pandas** a évolué récemment. Vous pouvez retrouver les contenus liés à **Pandas** dans les chapitres suivants:

- Introduction à **Pandas** et à la logique du *DataFrame* ;
- Associer des données avec **Pandas** : les jointures ;
- Manipuler des données avec **Pandas** : statistiques et restructuration ;
- **Pandas** : limites et écosystèmes alternatifs ;

Informations additionnelles

i Environnement Python

Ce site a été construit automatiquement par le biais d'une action **Github** utilisant le logiciel de publication reproductible **Quarto** (version 1.10.18).

L'environnement utilisé pour obtenir les résultats est reproductible par le biais d'**uv**. Le fichier **pyproject.toml** utilisé pour construire cet environnement est disponible sur le dépôt **linogaliana/python-datascientist**

```
[project]
name = "python-datascientist"
version = "0.1.0"
description = "Source code for Lino Galiana's Python for data science course"
readme = "README.md"
requires-python = "≥3.13,<3.14"
dependencies = [
    "altair≥6.0.0",
    "cartiflette",
```

```

    "contextily=1.6.2",
    "duckdb ≥ 0.10.1",
    "folium ≥ 0.19.6",
    "gdal=3.11.4",
    "graphviz=0.20.3",
    "great-tables ≥ 0.12.0",
    "gt-extras ≥ 0.0.8",
    "ipykernel ≥ 6.29.5",
    "jupyter ≥ 1.1.1",
    "jupyter-cache ≥ 1.0.0",
    "kaleido ≥ 0.2.1",
    "langchain-community ≥ 0.3.27",
    "loguru=0.7.3",
    "markdown ≥ 3.8",
    "nbcclient ≥ 0.10.0",
    "nbformat ≥ 5.10.4",
    "nltk ≥ 3.9.1",
    "pandas ≥ 3.0",
    "pip ≥ 25.1.1",
    "plotly ≥ 6.1.2",
    "plotnine ≥ 0.15",
    "polars ≥ 1.8.2",
    "pyarrow ≥ 17.0.0",
    "pynsee ≥ 0.1.8",
    "python-dotenv ≥ 1.0.1",
    "python-frontmatter ≥ 1.1.0",
    "pywaffle ≥ 1.1.1",
    "requests ≥ 2.32.3",
    "scikit-image ≥ 0.24.0",
    "scikit-learn ≥ 1.8.0",
    "scipy ≥ 1.13.0",
    "seaborn ≥ 0.13.2",
    "selenium < 4.39.0",
    "spacy ≥ 3.8.4",
    "webdriver-manager ≥ 4.0.2",
    "wordcloud=1.9.3",
]

[tool.uv.sources]
cartiflette = { git = "https://github.com/inseefrlab/cartiflette" }
gdal = [
    { index = "gdal-wheels", marker = "sys_platform == 'linux'", },
    { index = "geospatial-wheels", marker = "sys_platform == 'win32'", },
]

[[tool.uv.index]]
name = "geospatial-wheels"
url = "https://nathanjmcDougall.github.io/geospatial-wheels-index/"
explicit = true

[[tool.uv.index]]
name = "gdal-wheels"
url = "https://gitlab.com/api/v4/projects/61637378/packages/pypi/simple"
explicit = true

[dependency-groups]
dev = [

```

```
"nb-clean ≥ 4.0.1",  
]
```

Pour utiliser exactement le même environnement (version de **Python** et *packages*), se reporter à la [documentation d'uv](#).

Bibliographie