

# Premier pas vers l'industrialisation avec les pipelines scikit

Lino Galiana

Version du 29 septembre 2026

Les *pipelines* `Scikit` permettent d'intégrer de manière très flexible un ensemble d'opérations de pre-processing et d'entraînement de modèles dans une chaîne d'opérations. Il s'agit d'une approche particulièrement appropriée pour réduire la difficulté à changer d'algorithme ou pour faciliter la ré-application d'un code à de nouvelles données.

⚠ **PDF généré automatiquement.** Ce document est produit à partir du site du cours et peut présenter des problèmes de mise en forme. Pour une version à jour et adaptée à la lecture, consultez la page du cours : [pythonds.linogaliana.fr](https://pythonds.linogaliana.fr).

## Table des matières

|                                                                                     |           |
|-------------------------------------------------------------------------------------|-----------|
| <b>1 Pourquoi utiliser les <i>pipelines</i> ?</b>                                   | <b>2</b>  |
| 1.1 Définitions préalables                                                          | 2         |
| 1.2 Objectif                                                                        | 2         |
| 1.3 Les <i>pipelines</i> <code>Scikit</code>                                        | 2         |
| <b>2 Comment créer un <i>pipeline</i></b>                                           | <b>3</b>  |
| 2.1 Données utilisées                                                               | 3         |
| <b>3 Un premier pipeline : <i>random forest</i> sur des variables standardisées</b> | <b>6</b>  |
| 3.1 Définition des ensembles <i>train</i> et <i>test</i>                            | 7         |
| 3.2 Définition du premier <i>pipeline</i>                                           | 8         |
| 3.3 <i>Variable importance</i>                                                      | 9         |
| <b>4 Restriction du champ du modèle</b>                                             | <b>10</b> |
| <b>5 Recherche des hyperparamètres optimaux avec une validation croisée</b>         | <b>11</b> |
| <b>6 Prochaine étape</b>                                                            | <b>13</b> |
| <b>Références</b>                                                                   | <b>13</b> |
| Informations additionnelles                                                         | 13        |
| <b>Bibliographie</b>                                                                | <b>15</b> |

Ce chapitre présente la première application d'une journée de cours que j'ai donné à l'Université Dauphine dans le cadre des *PSL Data Week*.

Pour lire les données de manière efficace, nous proposons d'utiliser le *package* `duckdb`. Pour l'installer, voici la commande :

```
!pip install duckdb
```

# 1 Pourquoi utiliser les *pipelines* ?

## 1.1 Définitions préalables

Ce chapitre nous amènera à explorer plusieurs écosystèmes, pour lesquels on retrouve quelques buzz-words dont voici les définitions :

| Terme         | Définition                                                                                                                                                                           |
|---------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>DevOps</i> | Mouvement en ingénierie informatique et une pratique technique visant à l'unification du développement logiciel (dev) et de l'administration des infrastructures informatiques (ops) |
| <i>MLOps</i>  | Ensemble de pratiques qui vise à déployer et maintenir des modèles de machine learning en production de manière fiable et efficace                                                   |

Ce chapitre fera des références régulières au cours de 3e année de l'ENSAE «*Mise en production de projets data science*».

## 1.2 Objectif

Les chapitres précédents ont permis de montrer des bouts de code épars pour entraîner des modèles ou faire du *preprocessing*. Cette démarche est intéressante pour tâtonner mais risque d'être coûteuse ultérieurement s'il est nécessaire d'ajouter une étape de *preprocessing* ou de changer d'algorithme.

Les *pipelines* sont pensés pour simplifier la mise en production ultérieure d'un modèle de *machine learning*. Ils sont au coeur de la démarche de *MLOps* qui est présentée dans le cours de 3e année de l'ENSAE de «*Mise en production de projets data science*», qui vise à simplifier la mise en oeuvre opérationnelle de projets utilisant des techniques de *machine learning*.

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import pandas as pd
```

## 1.3 Les *pipelines* Scikit

Heureusement, **Scikit** propose un excellent outil pour proposer un cadre général pour créer une chaîne de production *machine learning*. Il s'agit des *pipelines*. Ils présentent de nombreux intérêts, parmi lesquels :

- Ils sont très **pratiques et lisibles**. On rentre des données en entrée, on n'appelle qu'une seule fois les méthodes `fit` et `predict` ce qui permet de s'assurer une gestion cohérente des transformations de variables, par exemple après l'appel d'un `StandardScaler` ;
- La **modularité** rend aisée la mise à jour d'un pipeline et renforce la capacité à le réutiliser ;
- Ils permettent de facilement chercher les hyperparamètres d'un modèle. Sans *pipeline*, écrire un code qui fait du *tuning* d'hyperparamètres peut être pénible. Avec les *pipelines*, c'est une ligne de code ;
- La **sécurité** d'être certain que les étapes de preprocessing sont bien appliquées aux jeux de données désirés avant l'estimation.



Tip

Un des intérêts des *pipelines* scikit est qu'ils fonctionnent aussi avec des méthodes qui ne sont pas issues de `scikit`.

Il est possible d'introduire un modèle de réseau de neurone `Keras` dans un pipeline `scikit`. Pour introduire un modèle économétrique `statsmodels` c'est un peu plus coûteux mais nous allons proposer des exemples qui peuvent servir de modèle et qui montrent que c'est faisable sans trop de difficulté.

## 2 Comment créer un *pipeline*

Un *pipeline* est un enchaînement d'opérations qu'on code en enchainant des pairs (*clé, valeur*) :

- la clé est le nom du pipeline, cela peut être utile lorsqu'on va représenter le *pipeline* sous forme de diagramme acyclique (visualisation DAG) ou qu'on veut afficher des informations sur une étape
- la valeur représente la transformation à mettre en oeuvre dans le *pipeline* (c'est-à-dire, à l'exception de la dernière étape, mettre en oeuvre une méthode `transform` et éventuellement une transformation inverse).

```
from sklearn.pipeline import Pipeline
from sklearn.svm import SVC
from sklearn.decomposition import PCA

estimators = [('reduce_dim', PCA()), ('clf', SVC())]
pipe = Pipeline(estimators)
pipe
```

Au sein d'une étape de *pipeline*, les paramètres d'un estimateur sont accessibles avec la notation `<estimator>__<parameter>`. Cela permet de fixer des valeurs pour les arguments des fonctions `scikit` qui sont appelées au sein d'un *pipeline*. C'est cela qui rendra l'approche des pipelines particulièrement utile pour la *grid search* :

```
from sklearn.model_selection import GridSearchCV
param_grid = {"reduce_dim__n_components": [2, 5, 10], "clf__C": [0.1, 10, 100]}
grid_search = GridSearchCV(pipe, param_grid=param_grid)
grid_search
```

Ces *pipelines* sont initialisés sans données, il s'agit d'une structure formelle que nous allons ensuite ajuster en entraînant des modèles.

### 2.1 Données utilisées

Nous allons utiliser les données de transactions immobilières `DVF` pour chercher la meilleure manière de prédire, sachant les caractéristiques d'un bien, son prix.

Ces données sont mises à disposition sur `data.gouv`. Néanmoins, le format csv n'étant pas pratique pour importer des jeux de données volumineux, nous proposons de privilégier la version `Parquet` mise à disposition par Eric Mauvière sur `data.gouv`. L'approche la plus efficace pour lire ces données est d'utiliser `DuckDB` afin de lire le fichier, extraire les colonnes d'intérêt puis passer à `Pandas` (pour en savoir plus sur l'intérêt de `DuckDB` pour lire des fichiers volumineux, vous pouvez consulter [ce post de blog](#) ou [celui-ci](#) écrit par Eric Mauvière).

Même si, en soi, les gains de temps sont faibles car **DuckDB** optimise les requêtes HTTPS nécessaires à l'import des données, nous proposons de télécharger les données pour réduire les besoins de bande passante.

```
import requests
import os

url = "https://www.data.gouv.fr/fr/datasets/r/56bde1e9-e214-408b-888d-34c57ff005c4"
file_name = "dvf.parquet"

# Check if the file already exists
if not os.path.exists(file_name):
    response = requests.get(url)

    if response.status_code == 200:
        with open(file_name, "wb") as f:
            f.write(response.content)
        print("Téléchargement réussi.")
    else:
        print(f"Échec du téléchargement. Code d'état : {response.status_code}")
else:
    print(f"Le fichier '{file_name}' existe déjà. Aucun téléchargement nécessaire.")
```

En premier lieu, puisque cela va faciliter les requêtes SQL ultérieures, on crée une vue :

```
import duckdb
duckdb.sql(f'CREATE OR REPLACE VIEW dvf AS SELECT * FROM read_parquet("dvf.parquet")')
```

Les données prennent la forme suivante :

```
duckdb.sql(f"SELECT * FROM dvf LIMIT 5")
```

Les variables que nous allons conserver sont les suivantes, nous allons les reformater pour la suite de l'exercice.

```
xvars = [
    "Date mutation", "Valeur fonciere",
    "Nombre de lots", "Code type local",
    "Nombre pieces principales"
]
xvars = ", ".join([f'"{s}"' for s in xvars])
```

```
mutations = duckdb.sql(
    f'''
    SELECT
    date_part('month', "Date mutation") AS month,
    substring("Code postal", 1, 2) AS dep,
    {xvars},
    COLUMNS('Surface Carrez.*')
    FROM dvf
    '''
).to_df()

colonnes_surface = mutations.columns[mutations.columns.str.startswith('Surface Carrez')]
mutations.loc[:, colonnes_surface] = mutations.loc[:, colonnes_surface].replace({' ': '.'},
regex=True).astype(float).fillna(0)
```

**i** Note

Le fichier `Parquet` mis à disposition sur `data.gouv` présente une incohérence de mise en forme de certaines colonnes à cause des virgules qui empêchent le formattage sous forme de colonne numérique.

Le code ci-dessus effectue la conversion adéquate au niveau de `Pandas`.

```
mutations.head(2)
```

Introduire un effet confinement Si vous travaillez avec les données de 2020, n'oubliez pas d'intégrer l'effet confinement dans vos modèles puisque cela a lourdement affecté les possibilités de transaction sur cette période, donc l'effet potentiel de certaines variables explicatives du prix.

Pour introduire cet effet, vous pouvez créer une variable indicatrice entre les dates en question:

```
mutations['confinement'] = (
    mutations['Date mutation']
    .between(pd.to_datetime("2020-03-17"), pd.to_datetime("2020-05-03"))
    .astype(int)
)
```

Comme nous travaillons sur les données de 2022, nous pouvons nous passer de cette variable.

Les données DVF proposent une observation par transaction. Ces transactions peuvent concerner plusieurs lots. Par exemple, un appartement avec garage et cave comportera trois lots.

Pour simplifier, on va créer une variable de surface qui agrège les différentes informations de surface disponibles dans le jeu de données. Les agréger revient à supposer que le modèle de fixation des prix est le même entre chaque lot. C'est une hypothèse simplificatrice qu'une personne plus experte du marché immobilier, ou qu'une approche propre de sélection de variable pourrait amener à nier. En effet, les variables en question sont faiblement corrélées les unes entre elles, à quelques exceptions près (Figure 1):

```
corr = mutations.loc[
    :,
    mutations.columns[mutations.columns.str.startswith('Surface Carrez')].tolist()
]
corr.columns = corr.columns.str.replace("Carrez du ", "")
corr = corr.corr()

mask = np.triu(np.ones_like(corr, dtype=bool))

cmap = sns.diverging_palette(230, 20, as_cmap=True)
```

```
fig, ax = plt.subplots(1)
g = sns.heatmap(
    corr, ax=ax,
    mask=mask,
    vmax=.3, center=0,
    square=True, linewidths=.5, cbar_kws={"shrink": .5},
    xticklabels=corr.columns.values,
    yticklabels=corr.columns.values, cmap=cmap, annot=True, fmt=".2f"
)
g
```

Figure 1

```
mutations['lprix'] = np.log(mutations["Valeur fonciere"])
mutations['surface'] = mutations.loc[:, colonnes_surface].sum(axis = 1).astype(int)
```

```
mutations['surface'] = mutations.loc[:, mutations.columns[mutations.columns.str.startswith('Surface Carrez')].tolist()].sum(axis = 1)
```

### 3 Un premier pipeline : *random forest* sur des variables standardisées

Notre premier *pipeline* va nous permettre d'intégrer ensemble:

1. Une étape de *preprocessing* avec la standardisation de variables
2. Une étape d'estimation du prix en utilisant un modèle de *random forest*


Pour le moment, on va prendre comme acquis un certain nombre de variables explicatives (les *features*) et les hyperparamètres du modèle.

L'algorithme des *random forest* est une technique statistique basée sur les arbres de décision. Elle a été définie explicitement par l'un des pionniers du *machine learning*, L. Breiman [1]. Il s'agit d'une [méthode ensembliste](#) puisqu'elle consiste à utiliser plusieurs algorithmes (en l'occurrence des arbres de décision) pour obtenir une meilleure prédiction que ne le permettraient chaque modèle isolément.

Les *random forest* sont une méthode d'agrégation<sup>1</sup> d'arbres de décision. On calcule  $K$  arbres de décision et en tire, par une méthode d'agrégation, une règle de décision moyenne qu'on va appliquer pour tirer une prédiction de nos données.

---

<sup>1</sup>Les *random forest* sont l'une des principales méthodes ensemblistes. Outre cette approche, les plus connues sont le *bagging* (*bootstrap aggregating*) et le *boosting* qui consistent à choisir la prédiction à privilégier selon des algorithmes de choix différents. Par exemple le *bagging* est une technique basée sur le vote majoritaire [2]. Cette technique s'inspire du *bootstrap* qui, en économétrie, consiste à ré-estimer sur  $K$  sous-échantillons aléatoires des données un estimateur afin d'en tirer, par exemple, un intervalle de confiance empirique à 95%. Le principe du *bagging* est le même. On ré-estime  $K$  fois notre estimateur (par exemple un arbre de décision) et propose une règle d'agrégation pour en tirer une règle moyennisée et donc une prédiction. Le *boosting* fonctionne selon un principe différent, basé sur l'optimisation de combinaisons de classifieurs faibles.



L'un des intérêts des *random forest* est qu'il existe des méthodes pour déterminer l'importance relative de chaque variable dans la prédiction.

Nous allons ici partir d'un *random forest* avec des valeurs d'hyperparamètres données, à savoir la profondeur de l'arbre.

### 3.1 Définition des ensembles *train* et *test*

Nous allons donc nous restreindre à un sous-ensemble de colonnes dans un premier temps.

Nous allons également ne conserver que les transactions inférieures à 5 millions d'euros (on anticipe que celles ayant un montant supérieur sont des transactions exceptionnelles dont le mécanisme de fixation du prix diffère)

```

mutations2 = mutations.drop(
    colonnes_surface.tolist() + ["Date mutation", "lprix"], # ajouter "confinement" si données 2020
    axis = "columns"
).copy()

mutations2 = mutations2.loc[mutations2['Valeur fonciere'] < 5e6] #keep only values below 5
millions

mutations2.columns = mutations2.columns.str.replace(" ", "_")
mutations2 = mutations2.dropna(subset = ['dep', 'Code_type_local', 'month'])
  
```

Notre *pipeline* va incorporer deux types de variables: les variables catégorielles et les variables numériques. Ces différents types vont bénéficier d'étapes de *preprocessing* différentes.

```

numeric_features = mutations2.columns[~mutations2.columns.isin(['dep', 'Code_type_local',
'month', 'Valeur_fonciere'])].tolist()
categorical_features = ['dep', 'Code_type_local', 'month']
  
```

Au passage, nous avons abandonné la variable de code postal pour privilégier le département afin de réduire la dimension de notre jeu de données. Si on voulait vraiment avoir un bon modèle, il faudrait

faire autrement car le code postal est probablement un très bon prédicteur du prix d'un bien, une fois que les caractéristiques du bien sont contrôlées.

### 💡 Exercice 1 : Découpage des échantillons

Nous allons stratifier notre échantillonnage de *train/test* par département afin de tenir compte, de manière minimale, de la géographie. Pour accélérer les calculs pour ce tutoriel, nous n'allons considérer que 30% des transactions observées sur chaque département.

Voici le code pour le faire:

```
mutations2 = mutations2.groupby('dep').sample(frac = 0.1, random_state = 123)
```

Avec la fonction adéquate de **Scikit**, faire un découpage de `mutations2` en *train* et *test sets* en suivant les consignes suivantes:

- 20% des données dans l'échantillon de *test* ;
- L'échantillonnage est stratifié par départements ;
- Pour avoir des résultats reproductibles, choisir une racine égale à 123.

## 3.2 Définition du premier *pipeline*

Pour commencer, nous allons fixer la taille des arbres de décision avec l'hyperparamètre `max_depth = 2`.

Notre *pipeline* va intégrer les étapes suivantes :

### 1. **Preprocessing** :

- Les variables numériques vont être standardisées avec un `StandardScaler`. Pour cela, nous allons utiliser la liste `numeric_features` définie précédemment.
- Les variables catégorielles vont être explosées avec un *one hot encoding* (méthode `OneHotEncoder` de **scikit**) Pour cela, nous allons utiliser la liste `categorical_features`

### 2. **Random forest** : nous allons appliquer l'estimateur *ad hoc* de **Scikit**.

### 💡 Exercice 2 : Construction d'un premier pipeline formel

1. Initialiser un *random forest* de profondeur 2. Fixer la racine à 123 pour avoir des résultats reproductibles.
2. La première étape du *pipeline* (nommer cette couche *preprocessor*) consiste à appliquer les étapes de *preprocessing* adaptées à chaque type de variables:
  - Pour les variables numériques, appliquer une étape d'imputation à la moyenne puis standardiser celles-ci
  - Pour les variables catégorielles, appliquer un *one hot encoding*
3. Appliquer comme couche de sortie le modèle défini plus tôt.

💡 Il est recommandé de s'aider de la documentation de **Scikit**. Si vous avez besoin d'un indice supplémentaire, consulter le pipeline présenté ci-dessous.

A l'issue de cet exercice, nous devrions obtenir le *pipeline* suivant.

Nous avons construit ce pipeline sous forme de couches successives. La couche `randomforest` prendra automatiquement le résultat de la couche `preprocessor` en *input*. La couche `features` permet d'introduire de manière relativement simple (quand on a les bonnes méthodes) la complexité du *preprocessing* sur données réelles dont les types divergent.

A cette étape, rien n'a encore été estimé. C'est très simple à mettre en oeuvre avec un *pipeline*.

### 💡 Exercice 3 : Mise en oeuvre du pipeline

1. Estimer les paramètres du modèle sur le jeu d'entraînement
2. Observer la manière dont les données d'entraînement sont transformées par l'étape de *preprocessing* avec les méthodes adéquates sur 4 observations de `X_train` tirées aléatoirement
3. Utiliser ce modèle pour prédire le prix sur l'échantillon de test. A partir de ces quelques prédictions, quel semble être le problème ?
4. Observer la manière dont ce *preprocessing* peut s'appliquer sur deux exemples fictifs :
  - Un appartement (`code_type_local = 2`) dans le 75, vendu au mois de mai, unique lot de la vente avec 3 pièces, faisant 75m<sup>2</sup> ;
  - Une maison (`code_type_local = 1`) dans le 06, vendue en décembre, dans une transaction avec 2 lots. La surface complète est de 180m<sup>2</sup> et le bien comporte 6 pièces.
5. Dédire sur ces deux exemples le prix prédit par le modèle.
6. Calculer et interpréter le RMSE sur l'échantillon de test. Ce modèle est-il satisfaisant ?

## 3.3 Variable importance

Les prédictions semblent avoir une assez faible variance, comme si des variables de seuils intervenaient. Nous allons donc devoir essayer de comprendre pourquoi.

La « *variable importance* » se réfère à la mesure de l'influence de chaque variable d'entrée sur la performance du modèle. L'impureté fait référence à l'incertitude ou à l'entropie présente dans un ensemble de données. Dans le contexte des *random forest*, cette mesure est souvent calculée en évaluant la réduction moyenne de l'impureté des nœuds de décision causée par une variable spécifique. Cette approche permet de quantifier l'importance des variables dans le processus de prise de décision du modèle, offrant ainsi des intuitions sur les caractéristiques les plus informatives pour la prédiction (plus de détails [sur ce blog](#)).

On ne va représenter, parmi notre ensemble important de colonnes, que celles qui ont une importance non nulle.

### 💡 Exercice 4 : Compréhension du modèle

1. Récupérer la *feature importance* directement depuis la couche adaptée de votre *pipeline*
2. Utiliser le code suivant pour calculer l'intervalle de confiance de cette mesure d'importance:

```
std = np.std([tree.feature_importances_ for tree in pipe['randomforest'].estimators_],
axis=0)
```

3. Représenter les variables d'importance non nulle. Qu'en concluez-vous ?

Le graphique d'importance des variables que vous devriez obtenir à l'issue de cet exercice est le suivant.

Les statistiques obtenues par le biais de cette *variable importance* sont un peu rudimentaires mais permettent déjà de comprendre le problème de notre modèle.

On voit donc que deux de nos variables déterminantes sont des effets fixes géographiques (qui servent à ajuster de la différence de prix entre Paris et les Hauts de Seine et le reste de la France), une autre variable est un effet fixe type de bien. Les deux variables qui pourraient introduire de la variabilité, à savoir la surface et, dans une moindre mesure, le nombre de lots, ont une importance moindre.

### i Note

Idéalement, on utiliserait **Yellowbrick** pour représenter l'importance des variables. Mais en l'état actuel du *pipeline* on a beaucoup de variables dont le poids est nul qui viennent polluer la visualisation. Vous pouvez consulter la [documentation de Yellowbrick](#) sur ce sujet

Les prédictions peuvent nous suggérer également qu'il y a un problème.

## 4 Restriction du champ du modèle

Mettre en oeuvre un bon modèle de prix au niveau France entière est complexe. Nous allons donc nous restreindre au champ suivant: les appartements dans Paris.

```
mutations_paris = mutations.drop(
    colonnes_surface.tolist() + ["Date mutation", "lprix"], # ajouter "confinement" si données 2020
    axis = "columns"
).copy()

mutations_paris = mutations_paris.loc[mutations_paris['Valeur fonciere'] < 5e6] #keep only values
below 5 millions

mutations_paris.columns = mutations_paris.columns.str.replace(" ", "_")
mutations_paris = mutations_paris.dropna(subset = ['dep', 'Code_type_local', 'month'])
mutations_paris = mutations_paris.loc[mutations_paris['dep'] == "75"]
mutations_paris = mutations_paris.loc[mutations_paris['Code_type_local'] ==
2].drop(['dep', 'Code_type_local'], axis = "columns")
mutations_paris = mutations_paris.loc[mutations_paris['surface'] > 0]
```

### 💡 Exercice 4 : Pipeline plus simple

Reprendre les codes précédents et reconstruire notre *pipeline* sur la nouvelle base en mettant en oeuvre une méthode de *boosting* plutôt qu'une forêt aléatoire.

*La correction de cet exercice est apparente pour simplifier les prochaines étapes mais essayez de faire celui-ci de vous-même.*

A l'issue de cet exercice, vous devriez avoir des *MDI* proches de celles-ci :

```
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.pipeline import make_pipeline, Pipeline
from sklearn.compose import make_column_transformer
from sklearn.model_selection import train_test_split

mutations_paris = mutations.drop(
    colonnes_surface.tolist() + ["Date mutation", "lprix"], # ajouter "confinement" si données 2020
    axis = "columns"
).copy()

mutations_paris = mutations_paris.loc[mutations_paris['Valeur fonciere'] < 5e6] #keep only values
below 5 millions

mutations_paris.columns = mutations_paris.columns.str.replace(" ", "_")
```

```

mutations_paris = mutations_paris.dropna(subset = ['dep', 'Code_type_local', 'month'])
mutations_paris = mutations_paris.loc[mutations_paris['dep'] == "75"]
mutations_paris = mutations_paris.loc[mutations_paris['Code_type_local'] == 2].drop(['dep', 'Code_type_local', 'Nombre_de_lots'], axis = "columns")
mutations_paris.loc[mutations_paris['surface'] > 0]

numeric_features = mutations_paris.columns[~mutations_paris.columns.isin(['month', 'Valeur_fonciere'])].tolist()
categorical_features = ['month']

reg = GradientBoostingRegressor(random_state=0)

numeric_pipeline = make_pipeline(
    SimpleImputer(),
    StandardScaler()
)
transformer = make_column_transformer(
    (numeric_pipeline, numeric_features),
    (OneHotEncoder(sparse_output = False, handle_unknown = "ignore"), categorical_features))
pipe = Pipeline(steps=[('preprocessor', transformer),
                       ('boosting', reg)])

X_train, X_test, y_train, y_test = train_test_split(
    mutations_paris.drop("Valeur_fonciere", axis = 1),
    mutations_paris["Valeur_fonciere"],
    test_size = 0.2, random_state = 123
)

pipe.fit(X_train, y_train)

pd.DataFrame(
    pipe["boosting"].feature_importances_,
    index = pipe[:-1].get_feature_names_out()
)

```

## 5 Recherche des hyperparamètres optimaux avec une validation croisée

On détecte que le premier modèle n'est pas très bon et ne nous aidera pas vraiment à évaluer de manière fiable l'appartement de nos rêves.

On va essayer de voir si notre modèle ne serait pas meilleur avec des hyperparamètres plus adaptés. Après tout, nous avons choisi par défaut la profondeur de l'arbre mais c'était un choix au doigt mouillé.

**?** Quels sont les hyperparamètres qu'on peut essayer d'optimiser ?

```
pipe['boosting'].get_params()
```

Un [détour par la documentation](#) nous aide à comprendre ceux sur lesquels on va jouer. Par exemple, il serait absurde de jouer sur le paramètre `random_state` qui est la racine du générateur pseudo-aléatoire.

```
X = pd.concat((X_train, X_test), axis=0)
Y = np.concatenate([y_train, y_test])
```

Nous allons nous contenter de jouer sur les paramètres:

- `n_estimators`: Le nombre d'arbres de décision que notre forêt contient
- `max_depth`: La profondeur de chaque arbre

Il existe plusieurs manières de faire de la validation croisée. Nous allons ici utiliser la *grid search* qui consiste à estimer et tester le modèle sur chaque combinaison d'une grille de paramètres et sélectionner le couple de valeurs des hyperparamètres amenant à la meilleure prédiction. Par défaut, `scikit` effectue une *5-fold cross validation*. Nous n'allons pas changer ce comportement.

Comme expliqué précédemment, les paramètres s'appellent sous la forme `<step>__<parameter_name>`

La validation croisée pouvant être très consommatrice de temps, nous n'allons l'effectuer que sur un nombre réduit de valeurs de notre grille. Il est possible de passer la liste des valeurs à passer au crible sous forme de liste (comme nous allons le proposer pour l'argument `max_depth` dans l'exercice ci-dessous) ou sous forme d'`array` (comme nous allons le proposer pour l'argument `n_estimators`) ce qui est souvent pratique pour générer un criblage d'un intervalle avec `np.linspace`.

#### 💡 Tip

Les estimations sont, par défaut, menées de manière séquentielle (l'une après l'autre). Nous sommes cependant face à un problème *embarrassingly parallel*. Pour gagner en performance, il est recommandé d'utiliser l'argument `n_jobs=-1`.

```
import numpy as np
from sklearn.model_selection import GridSearchCV

import time

start_time = time.time()
# Parameters of pipelines can be set using '__' separated parameter names:
param_grid = {
    "boosting__n_estimators": np.linspace(5, 25, 5).astype(int),
    "boosting__max_depth": [2, 4]
}
grid_search = GridSearchCV(pipe, param_grid=param_grid)
grid_search.fit(X_train, y_train)

end_time = time.time()

print(f"Elapsed time : {int(end_time - start_time)} seconds")
```

```
grid_search.best_params_
grid_search.best_estimator_
```

Toutes les performances sur les ensembles d'échantillons et de test sur la grille d'hyperparamètres sont disponibles dans l'attribut:

```
perf_random_forest = pd.DataFrame(grid_search.cv_results_)
```

Regardons les résultats moyens pour chaque valeur des hyperparamètres:

```
fig, ax = plt.subplots(1)
g = sns.lineplot(data = perf_random_forest, ax = ax,
                  x = "param_boosting__n_estimators",
                  y = "mean_test_score",
                  hue = "param_boosting__max_depth")
g.set(xlabel='Number of estimators', ylabel='Mean score on test sample')
g
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left', borderaxespad=0,
           title='Depth of trees')
```

Globalement, à profondeur d'arbre donnée, le nombre d'arbres affecte la performance. Changer la profondeur de l'arbre améliore la performance de manière plus marquée.

Maintenant, il nous reste à re-entraîner le modèle avec ces nouveaux paramètres sur l'ensemble du jeu de *train* et l'évaluer sur l'ensemble du jeu de *test* :

```
pipe_optimal = grid_search.best_estimator_
pipe_optimal.fit(X_train, y_train)

compar = pd.DataFrame([y_test, pipe_optimal.predict(X_test)]).T
compar.columns = ['obs', 'pred']
compar['diff'] = compar.obs - compar.pred
```

On obtient le RMSE suivant :

Et si on regarde la qualité en prédiction:

On obtient plus de variance dans la prédiction, c'est déjà un peu mieux. Cependant, cela reste décevant pour plusieurs raisons:

- nous n'avons pas fait d'étape de sélection de variable
- nous n'avons pas cherché à déterminer si la variable à prédire la plus pertinente était le prix ou une transformation de celle-ci (par exemple le prix au  $m^2$ )

## 6 Prochaine étape

Nous avons un modèle certes perfectible mais fonctionnel. La question qui se pose maintenant c'est d'essayer d'en faire quelque chose au service des utilisateurs. Cela nous amène vers la question de la **mise en production**.

Ceci est l'objet du prochain chapitre. Il s'agira d'une version introductive des enjeux évoqués dans le cadre du cours de 3e année de [mise en production de projets de data science](#).

## Références

### Informations additionnelles

**i** Environnement Python

Ce site a été construit automatiquement par le biais d'une action [Github](#) utilisant le logiciel de publication reproductible [Quarto](#) (version 1.10.18).

L'environnement utilisé pour obtenir les résultats est reproductible par le biais d'[uv](#). Le fichier [pyproject.toml](#) utilisé pour construire cet environnement est disponible sur le dépôt [linogaliana/python-datascientist](#)

```
[project]
name = "python-datascientist"
version = "0.1.0"
description = "Source code for Lino Galiana's Python for data science course"
readme = "README.md"
requires-python = "≥3.13,<3.14"
dependencies = [
    "altair≥6.0.0",
    "cartiflette",
    "contextily=1.6.2",
    "duckdb≥0.10.1",
    "folium≥0.19.6",
    "gdal=3.11.4",
    "graphviz=0.20.3",
    "great-tables≥0.12.0",
    "gt-extras≥0.0.8",
    "ipykernel≥6.29.5",
    "jupyter≥1.1.1",
    "jupyter-cache≥1.0.0",
    "kaleido≥0.2.1",
    "langchain-community≥0.3.27",
    "loguru=0.7.3",
    "markdown≥3.8",
    "nbcClient≥0.10.0",
    "nbformat≥5.10.4",
    "nltk≥3.9.1",
    "pandas≥3.0",
    "pip≥25.1.1",
    "plotly≥6.1.2",
    "plotnine≥0.15",
    "polars≥1.8.2",
    "pyarrow≥17.0.0",
    "pynsee≥0.1.8",
    "python-dotenv≥1.0.1",
    "python-frontmatter≥1.1.0",
    "pywaffle≥1.1.1",
    "requests≥2.32.3",
    "scikit-image≥0.24.0",
    "scikit-learn≥1.8.0",
    "scipy≥1.13.0",
    "seaborn≥0.13.2",
    "selenium<4.39.0",
    "spacy≥3.8.4",
    "webdriver-manager≥4.0.2",
    "wordcloud=1.9.3",
]

[tool.uv.sources]
cartiflette = { git = "https://github.com/inseefrlab/cartiflette" }
gdal = [
    { index = "gdal-wheels", marker = "sys_platform == 'linux'", }
```

```
{ index = "geospatial_wheels", marker = "sys_platform == 'win32'" },
]

[[tool.uv.index]]
name = "geospatial_wheels"
url = "https://nathanjmcDougall.github.io/geospatial-wheels-index/"
explicit = true

[[tool.uv.index]]
name = "gdal-wheels"
url = "https://gitlab.com/api/v4/projects/61637378/packages/pypi/simple"
explicit = true

[dependency-groups]
dev = [
    "nb-clean ≥ 4.0.1",
]
```

Pour utiliser exactement le même environnement (version de `Python` et `packages`), se reporter à la [documentation d'uv](#).

## Bibliographie

- [1] L. Breiman, « Random forests », *Machine learning*, vol. 45, p. 5-32, 2001.
- [2] L. Breiman, « Bagging predictors », *Machine learning*, vol. 24, p. 123-140, 1996.